

《机器学习》（周志华·西瓜书）

第 1–11 章完整复习资料（含模拟试题与速记手册）

子冉一人 整理

2026 年 7 月 12 日

目录

第一章 绪论	3
第二章 模型评估与选择	6
第三章 线性模型	10
第四章 决策树	14
第五章 神经网络	18
第六章 支持向量机	21
第七章 贝叶斯分类器	25
第八章 集成学习	29
第九章 聚类	33
第十章 降维与度量学习	37
第十一章 特征选择与稀疏学习	41
第十二章 计算题专项练习	45
第十三章 模拟试题	55
第十四章 考前速记手册	60

第1章 绪论

§ 知识复习

1.1 机器学习的基本概念

- **机器学习**：通过计算手段，利用经验（数据）改善系统自身性能的方法。
- **基本术语**：样本（示例）、特征（属性）、特征空间、标签（标记）、训练集、测试集。
- **分类与回归**：分类是预测离散值，回归是预测连续值。
- **监督学习与无监督学习**：监督学习使用有标签数据（分类、回归），无监督学习使用无标签数据（聚类）。

1.2 假设空间与归纳偏好

- **假设空间**：所有可能的函数（模型）构成的集合。学习过程是在假设空间中搜索与训练集一致的假设。
- **版本空间**：与训练集一致的假设构成的集合。
- **归纳偏好**：学习算法对某种假设的偏好。奥卡姆剃刀：“如无必要，勿增实体——选择最简单的假设。”
- **NFL 定理**（没有免费午餐定理）：所有学习算法的期望性能相同，不存在普遍最优的算法，算法的优劣取决于问题本身。

1.3 机器学习的发展史

- **符号主义**（决策树、归纳逻辑）、**连接主义**（神经网络）、**统计学习**（SVM）、**深度学习**。
- **相关领域**：数据挖掘、计算机视觉、自然语言处理、机器人学等。

题目

一、填空题

1. 机器学习利用_____来改善系统自身的性能。
2. 在监督学习中，预测离散值的任务称为_____，预测连续值的任务称为_____。
3. 与训练集一致的假设构成的集合称为_____。
4. NFL 定理的全称是_____定理，它表明不存在普遍最优的学习算法。
5. “如无必要，勿增实体”被称为_____原则。

二、选择题

1. 以下哪项不属于机器学习的基本术语？
(A) 样本
(B) 特征
(C) 算法复杂度
(D) 训练集
2. 关于归纳偏好，以下说法正确的是：
(A) 所有算法的归纳偏好相同
(B) 归纳偏好越强越好
(C) 归纳偏好是学习算法对某种假设的偏好
(D) NFL 定理否定了归纳偏好的重要性
3. 无监督学习的典型任务是：
(A) 分类
(B) 回归
(C) 聚类
(D) 标注
4. 关于 NFL 定理，下列说法错误的是：
(A) 所有学习算法的期望性能相同
(B) NFL 定理表明具体问题中算法可能有优劣
(C) NFL 定理说明算法选择不重要
(D) NFL 定理成立需对所有问题平均
5. 奥卡姆剃刀原则在机器学习中体现为：

参考答案与解析

一、填空题答案

1. 经验（数据）
2. 分类；回归
3. 版本空间
4. 没有免费午餐（No Free Lunch）
5. 奥卡姆剃刀（Occam's razor）

二、选择题答案

1. C（算法复杂度不属于机器学习基本术语）
2. C（归纳偏好是学习算法对某种假设的偏好）
3. C（聚类是无监督学习的典型任务）
4. C（NFL 定理并不否定在具体问题中精心选择算法的重要性）
5. B（奥卡姆剃刀倾向于选择最简单的假设）

三、简答题参考要点

1. 基本流程：收集数据 → 数据预处理 → 特征工程 → 模型选择 → 训练 → 评估 → 调参 → 测试。
训练集用于学习模型参数；验证集用于模型选择和调参；测试集用于评估最终模型的泛化性能。
2. NFL 定理指出在所有可能的分类问题上所有算法的期望性能相同。但这并不意味着算法选择不重要——因为实际中我们只关心具体问题而非所有可能问题的平均。不同算法有不同的归纳偏好，对特定问题可能效果差异很大，因此需要根据问题的特点选择合适算法。

第2章 模型评估与选择

§ 知识复习

2.1 经验误差与过拟合

- 错误率：分类错误的样本数占总样本数的比例。
- 精度： $1 - \text{错误率}$ 。
- 误差：学习器的实际预测输出与样本真实值之间的差异。
 - 训练误差（经验误差）：在训练集上的误差。
 - 泛化误差：在新样本上的误差。
- 过拟合：学习器把训练样本学得“好”，将训练样本自身特点当作所有潜在样本的一般性质，导致泛化性能下降。
- 欠拟合：对训练样本的一般性质尚未学好。
- 防止过拟合的常用方法：
 - 正则化（**Regularization**）：在损失函数中加入模型复杂度惩罚项（如 L_1 、 L_2 正则化），限制权重的大小，避免模型过度拟合训练数据中的噪声。
 - 早停（**Early Stopping**）：在训练过程中监控验证集上的性能，当验证误差不再下降时提前终止训练，防止模型继续学习训练集中的噪声模式。
 - 数据增强（**Data Augmentation**）：通过旋转、翻转、缩放等方式人为扩充训练数据的多样性，使模型接触到更多变体，提高泛化能力。
 - 丢弃法（**Dropout**）：训练时随机丢弃一定比例的神经元，迫使网络学习冗余表示，降低对特定神经元的依赖。

2.2 评估方法

- 留出法：将数据集按比例分为训练集和测试集（通常 $2/3$ $4/5$ 训练，余下测试），注意保持数据分布一致性（分层采样）。
- 交叉验证法：将数据集分为 k 份，每次用 $k-1$ 份训练、1 份测试，重复 k 次。常用 $k = 10$ 。
- 留一法： $k = n$ （样本数）的特殊交叉验证。评估结果准确但计算开销大。

- **自助法 (Bootstrapping)**: 有放回采样, 产生 m 个样本的训练集。约 36.8% 的样本未出现在训练集中 (用作测试集)。适合小数据集。

2.3 性能度量

- **混淆矩阵**:

	预测正例	预测反例
真实正例	TP	FN
真实反例	FP	TN

- **准确率 (Accuracy)**: $A = \frac{TP + TN}{TP + FP + FN + TN}$, 所有样本中预测正确的比例。
- **查准率 / 精确率 (Precision)**: $P = \frac{TP}{TP + FP}$, 预测为正例的样本中实际为正例的比例。
- **查全率 / 召回率 (Recall / TPR)**: $R = \frac{TP}{TP + FN}$, 实际为正例的样本中被正确预测的比例。
- **假正率 (FPR)**: $FPR = \frac{FP}{FP + TN}$, 实际为反例的样本中被错误预测为正例的比例。
- F_1 : $F_1 = \frac{2 \times P \times R}{P + R}$, 查准率和查全率的调和平均。
- **ROC 与 AUC**: ROC 曲线以 FPR 为横轴、TPR 为纵轴, 反映分类器在不同阈值下的性能; AUC 为曲线下面积, 值越大性能越好。AUC=1 为完美分类器, AUC=0.5 为随机猜测。
- **代价敏感错误率**: 不同类型错误赋予不同代价, 总代价为各类错误的加权和。

2.4 偏差与方差

- **偏差-方差分解**: 泛化误差 = 偏差² + 方差 + 噪声。
- **偏差**: 期望预测与真实值的偏离程度 (欠拟合的度量)。
- **方差**: 预测的波动程度 (过拟合的度量)。
- **偏差与方差存在权衡 (trade-off)**: 模型越复杂, 方差增大、偏差减小。

题目

一、填空题

1. 分类错误的样本数占总样本数的比例称为_____。
2. 学习器在训练集上的误差称为_____；在新样本上的误差称为_____。
3. 留出法中，为保持数据分布一致性，常采用_____ 采样。
4. 当模型过于复杂时，容易发生_____；当模型过于简单时，容易发生_____。
5. ROC 曲线的横轴是_____，纵轴是_____。

二、选择题

1. 10 折交叉验证中，每次用于训练的样本比例约为：
(A) 90%
(B) 80%
(C) 70%
(D) 100%
2. 关于偏差与方差，以下说法正确的是：
(A) 偏差越大，模型越复杂
(B) 方差越大，模型越可能欠拟合
(C) 随着模型复杂度增加，偏差降低、方差升高
(D) 模型复杂度与偏差方差无关
3. 假正率（FPR）的计算公式是：
(A) $FP/(TP + FN)$
(B) $FP/(FP + TN)$
(C) $TP/(TP + FP)$
(D) $TP/(TP + FN)$
4. 自助法中，约有百分之多少的样本不会出现在训练集中？
(A) 63.2%
(B) 36.8%
(C) 50%
(D) 26.4%

参考答案与解析

一、填空题答案

1. 错误率
2. 训练误差（经验误差）；泛化误差
3. 分层（Stratified）
4. 过拟合；欠拟合
5. 假正率（FPR）；真正率（TPR）

二、选择题答案

1. A（10 折交叉验证每次用 9 折训练，即 90%）
2. C（复杂度增加时偏差降低、方差升高）
3. B（ $FPR = FP/(FP + TN)$ ）
4. B（ $e^{-1} \approx 36.8\%$ 未出现在自助采样训练集中）
5. A（ $F_1 = 2 \times 0.8 \times 0.6/(0.8 + 0.6) = 0.96/1.4 \approx 0.6857$ ）

三、计算题答案

1. (1) $P = TP/(TP + FP) = 40/50 = 0.8$;
(2) $R = TP/(TP + FN) = 40/60 \approx 0.667$;
(3) $F_1 = 2 \times 0.8 \times 0.667/(0.8 + 0.667) \approx 0.727$;
(4) 错误率 $= (FP + FN)/100 = 30/100 = 0.3$ 。

四、概念题答案

1. **过拟合**指学习器把训练样本学得太“好”，将训练样本自身特点当作所有潜在样本的一般性质，导致泛化性能下降。
三种防止过拟合的方法：
(1) **正则化**：在损失函数中加入模型复杂度惩罚项（如 L_2 范数），限制权重过大，防止模型过度拟合训练数据中的噪声。
(2) **早停（Early Stopping）**：用验证集监控训练过程，当验证误差不再下降时提前终止，防止继续学习噪声。
(3) **数据增强**：通过旋转、翻转等变换人为扩充训练数据规模，提高模型泛化能力。
（答出正则化、早停、Dropout、数据增强、交叉验证中任意三种即可）
2. **偏差-方差分解**将泛化误差分解为偏差、方差和噪声三部分。**偏差**度量期望预测与真实值的偏离程度，反映欠拟合程度；**方差**度量预测结果的波动程度，反映过拟合程度。当模型复杂度增加时，模型对训练数据的拟合能力增强，偏差降低（更接近真实值）；但同时模型对训练数据中的噪声也更加敏感，在不同训练集上的预测结果差异增大，因此方差升高。偏差与方差之间存在**权衡（trade-off）**。

五、综合计算题答案

第3章 线性模型

§ 知识复习

3.1 基本形式

- 线性模型: $f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$, 其中 $\mathbf{w}$ 为权重向量, b 为偏置。
- 线性模型形式简单、可解释性强 (权重反映特征重要性)。

3.2 线性回归

- 最小二乘法: 最小化均方误差 $E = \sum_{i=1}^m (y_i - \mathbf{w}^T \mathbf{x}_i - b)^2$ 。
- 多元线性回归: $\hat{\mathbf{w}}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$ 。
- 对数线性回归: $\ln y = \mathbf{w}^T \mathbf{x} + b$, 将线性模型的输出映射到非线性空间。
- 广义线性模型: $y = g^{-1}(\mathbf{w}^T \mathbf{x} + b)$, $g(\cdot)$ 为联系函数 (link function)。

3.3 对数几率回归 (逻辑回归)

- 用于分类任务, 预测 $y \in \{0, 1\}$ 。
- 对数几率函数 (Sigmoid): $y = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}}$ 。
- 几率: $\frac{y}{1-y}$ 表示样本为正例的相对可能性。
- 通过极大似然估计求解参数: 最大化对数似然 $\ell(\mathbf{w}, b) = \sum_{i=1}^m \ln p(y_i | \mathbf{x}_i; \mathbf{w}, b)$ 。

3.4 线性判别分析 (LDA)

- 将样本投影到一条直线上, 使同类投影点尽可能接近、异类投影点尽可能远离。
- 类间散度矩阵 S_b 与类内散度矩阵 S_w 。
- 优化目标: 最大化 $\frac{\mathbf{w}^T S_b \mathbf{w}}{\mathbf{w}^T S_w \mathbf{w}}$ (广义瑞利商)。

3.5 多分类学习

- 一对一 (OvO): $N(N-1)/2$ 个二分类器, 投票决定。
- 一对多 (OvR): N 个二分类器, 置信度最高的获胜。
- 多对多 (MvM): 用纠错输出码 (ECOC) 处理。

3.6 类别不平衡问题

- 再缩放 (rescaling): 调整决策阈值, $\frac{y'}{1-y'} = \frac{y}{1-y} \times \frac{m^-}{m^+}$ 。

- 欠采样: 去除多数类样本; 过采样: 增加少数类样本 (如 SMOTE)。

题目

一、填空题

1. 线性回归中常用_____法来最小化均方误差。
2. 对数几率回归虽然名为“回归”，但实际上用于_____任务。
3. 在逻辑回归中，用于将线性输出映射到 $[0, 1]$ 区间的函数称为_____函数。
4. LDA 的全称是_____，其优化目标是最大化_____商。
5. N 个类别的 OvO 策略需要训练_____个二分类器。

二、选择题

1. 线性模型 $f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$ 中， $\mathbf{w}$ 的物理含义是：
(A) 偏置项
(B) 各特征的权重
(C) 样本的标签
(D) 学习率
2. 以下哪个不是处理类别不平衡问题的方法？
(A) 欠采样
(B) 过采样
(C) 降维
(D) 阈值移动
3. 关于 LDA，下列说法正确的是：
(A) 最大化类内散度、最小化类间散度
(B) 最小化类内散度、最大化类间散度
(C) 只考虑类间散度
(D) 只考虑类内散度
4. 对数几率回归中，极大似然估计的目的是：
(A) 最小化预测误差
(B) 最大化样本属于真实标签的概率
(C) 最小化模型复杂度
(D) 最大化特征数量
5. 广义线性模型中，联系函数（link function）的作用是：
(A) 增大模型复杂度

参考答案与解析

一、填空题答案

1. 最小二乘
2. 分类
3. Sigmoid (对数几率)
4. 线性判别分析 (Linear Discriminant Analysis); 广义瑞利
5. $N(N-1)/2$

二、选择题答案

1. B ($\mathbf{w}$ 是特征权重向量)
2. C (降维不是处理类别不平衡的方法)
3. B (LDA 最小化类内散度、最大化类间散度)
4. B (极大似然估计最大化样本观测概率)
5. B (联系函数实现非线性变换)

三、计算题答案

1. $\bar{x} = 2, \bar{y} = 8/3; \hat{w} = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2} = \frac{(-1)(-5/3) + (0)(1/3) + (1)(4/3)}{1 + 0 + 1} = \frac{3}{2} = 1.5;$
 $\hat{b} = \bar{y} - \hat{w}\bar{x} = 8/3 - 3 = -1/3。$
 因此回归模型为: $y = 1.5x - 1/3。$

四、概念题答案

1. 最小二乘法的目标函数: $E = \sum_{i=1}^m (y_i - \mathbf{w}^T \mathbf{x}_i - b)^2。$
 矩阵形式的闭式解: $\hat{\mathbf{w}}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}。$
 当 $\mathbf{X}^T \mathbf{X}$ 不可逆时 (例如特征数大于样本数、或特征之间存在多重共线性), 该闭式解不可计算。此时需使用梯度下降等迭代方法求解, 或加入正则化项。
2. Sigmoid 函数 $y = \frac{1}{1+e^{-z}}$ 将任意实数 z 映射到 $(0,1)$ 区间, 使输出可以解释为概率。
 当 $z \rightarrow -\infty$ 时 $y \rightarrow 0$, 当 $z \rightarrow +\infty$ 时 $y \rightarrow 1。$
 在逻辑回归中 $z = \mathbf{w}^T \mathbf{x} + b$, 因此线性输出被映射为 $P(y=1|\mathbf{x})$ 的后验概率估计。
 输出值范围为 $(0,1)$, 开区间 (不会精确等于 0 或 1)。

五、推导题答案

1. 一元线性回归 $y = wx + b$, 损失函数为均方误差 $E = \sum_{i=1}^m (y_i - wx_i - b)^2。$
 分别对 w 和 b 求偏导:
 $\frac{\partial E}{\partial w} = -2 \sum_{i=1}^m x_i (y_i - wx_i - b);$
 $\frac{\partial E}{\partial b} = -2 \sum_{i=1}^m (y_i - wx_i - b)。$
 令偏导数为 0;

第4章 决策树

§ 知识复习

4.1 基本流程

- **决策树**：基于树结构进行决策，每个内部节点对应一个属性测试，每个分支对应一个测试输出，每个叶节点对应一个决策结果。
- **分治策略**：递归地将问题分解为一系列子问题。
- **递归返回条件**：(1) 当前节点样本全属同一类别；(2) 当前属性集为空或样本在所有属性上取值相同；(3) 当前节点样本集为空。

4.2 划分选择

- **信息增益 (ID3)**： $\text{Gain}(D, a) = \text{Ent}(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Ent}(D^v)$ 。信息增益越大，划分效果越好。偏向取值较多的属性。
- **信息熵**： $\text{Ent}(D) = - \sum_{k=1}^{|\mathcal{Y}|} p_k \log_2 p_k$ ，值越小纯度越高。
- **增益率 (C4.5)**： $\text{Gain_ratio}(D, a) = \frac{\text{Gain}(D, a)}{\text{IV}(a)}$ ，其中 $\text{IV}(a) = - \sum_{v=1}^V \frac{|D^v|}{|D|} \log_2 \frac{|D^v|}{|D|}$ (属性固有值)。偏向取值较少的属性。C4.5 采用启发式：先选信息增益高于平均的属性，再从中选增益率最高的。
- **基尼指数 (CART)**： $\text{Gini}(D) = \sum_{k=1}^{|\mathcal{Y}|} \sum_{k' \neq k} p_k p_{k'} = 1 - \sum_{k=1}^{|\mathcal{Y}|} p_k^2$ 。基尼指数越小，纯度越高。CART 选择基尼指数最小的属性。

4.3 剪枝处理

- **预剪枝**：在决策树生成过程中，若当前划分不能带来泛化性能提升，则停止划分。优点：效率高；缺点：可能欠拟合。
- **后剪枝**：先生成完整决策树，再自底向上对非叶节点进行考察，若替换为叶节点能提升泛化性能则剪枝。优点：欠拟合风险小；缺点：效率低。

4.4 连续值与缺失值处理

- **连续值处理**：采用二分法 (C4.5)，将连续属性排序后取相邻值的中点作为候选划分点。

- **缺失值处理：**C4.5 方法——(1) 选择划分属性时，仅用无缺失样本；(2) 确定划分后，有缺失的样本按权重分配到各分支。

4.5 多变量决策树

- 传统决策树的分类边界平行于坐标轴。**多变量决策树**（斜决策树）使用多个属性的线性组合作为划分，分类边界不再平行于坐标轴。

题目

一、填空题

1. 决策树学习的策略本质上是_____，将复杂问题分解为一系列简单判断。
2. 信息熵越_____，数据集纯度越高。
3. ID3 算法使用_____ 作为划分选择准则，该准则偏向取值较_____ 的属性。
4. C4.5 算法使用_____ 作为划分选择准则，其启发式策略是先选出信息增益_____ 平均水平的属性，再从中选择增益率最_____ 的。
5. CART 算法使用_____ 指数作为划分准则，该指数越_____，纯度越高。
6. 预剪枝的优点是效率高，缺点是可能带来_____ 的风险。
7. 后剪枝的优点是欠拟合风险小，缺点是_____。

二、选择题

1. 信息增益计算公式为：

- (A) $\text{Gain} = \text{Ent}(D) + \sum \frac{|D^v|}{|D|} \text{Ent}(D^v)$
- (B) $\text{Gain} = \text{Ent}(D) - \sum \frac{|D^v|}{|D|} \text{Ent}(D^v)$
- (C) $\text{Gain} = \sum \frac{|D^v|}{|D|} \text{Ent}(D^v) - \text{Ent}(D)$
- (D) $\text{Gain} = 1 - \sum p_k^2$

2. 属性固有值 $\text{IV}(a)$ 的计算式中，若属性 A 有 3 个取值且样本均匀分布，则 $\text{IV}(A)$ 约为：

- (A) 0
- (B) $\log_2 3 \approx 1.585$
- (C) 1
- (D) 3

3. 关于剪枝，以下说法正确的是：

- (A) 预剪枝比后剪枝更不容易欠拟合
- (B) 后剪枝比预剪枝效率高
- (C) 后剪枝通常比预剪枝保留更复杂的树
- (D) 预剪枝和后剪枝结果完全相同

4. 决策树处理连续值时，常采用的方法是：

- (A) 直接丢弃连续属性

参考答案与解析

一、填空题答案

1. 分治
2. 小（低）
3. 信息增益；多
4. 增益率；高于；高
5. 基尼；小
6. 欠拟合
7. 效率低（时间开销大）

二、选择题答案

1. B（信息增益 $= \text{Ent}(D) - \sum \frac{|D^v|}{|D|} \text{Ent}(D^v)$ ）
2. B（ $-\frac{1}{3} \log_2 \frac{1}{3} \times 3 = \log_2 3 \approx 1.585$ ）
3. C（后剪枝通常保留更复杂的树，欠拟合风险小）
4. B（C4.5 采用二分法处理连续值）
5. B（多变量决策树使用线性组合，边界不平行于坐标轴）

三、计算题答案

1. $\text{Gain}(D, A) = 1.000 - \frac{4}{8} \times 0.811 - \frac{4}{8} \times 0.811 = 1.000 - 0.811 = 0.189$ 。
2. $\text{IV} = -\frac{1}{4} \log_2 \frac{1}{4} \times 4 = \log_2 4 = 2.000$ 。

四、概念题答案

1. **信息增益（ID3）**：偏向取值较多的属性，优点是直观易懂。
增益率（C4.5）：对取值较多的属性有惩罚，偏好取值较少的属性。C4.5 的启发式策略是先选信息增益高于平均的属性，再从中选增益率最高的，避免了两者的极端偏好。
基尼指数（CART）：计算量更小（无需对数运算），且偏向取值较多属性（与信息增益类似）。
当属性取值数目差异较大时优先使用增益率（C4.5）；当需要构建二叉树时优先使用基尼指数（CART）。
2. **剪枝的目的**：防止过拟合，提高决策树的泛化能力。
预剪枝：在构建过程中，若当前划分不能带来泛化性能提升，则停止划分。优点是效率高、速度快；缺点是可能欠拟合（当前虽不能提升，但后续划分可能提升）。
后剪枝：先生成完整树，再自底向上将非叶节点替换为叶节点，若泛化性能提升则剪枝。优点是欠拟合风险小，效果通常更好；缺点是时间开销大。

五、计算题答案

第5章 神经网络

§ 知识复习

5.1 神经元模型

- **M-P 神经元**: 接收 n 个输入信号, 乘以权重后求和, 减去阈值, 通过激活函数输出。
- **激活函数**: 阶跃函数 (简单但不可导)、Sigmoid 函数 (光滑可导, 常用于 BP 算法)。

5.2 感知机与多层网络

- **感知机**: 只有输入层和输出层 (无隐层), 只能处理线性可分问题 (如与、或、非)。
- **学习规则**: 预测正确时不调整权重, 预测错误时调整: $\Delta w_i = \eta(y - \hat{y})x_i$ 。
- **多层前馈网络**: 含隐层的前馈神经网络, 解决非线性可分问题 (如异或), 通用逼近能力。

5.3 误差逆传播 (BP) 算法

- **BP 算法的核心思想**: 计算输出与真实值的误差, 从后向前逐层传播误差, 据此更新各层权重。
- **标准 BP**: 每处理一个样本就更新一次权重 (更新快但震荡)。
- **累积 BP**: 处理完整个训练集后统一更新权重 (更稳定)。
- **过拟合缓解**: 早停 (early stopping)、正则化 (在误差函数中加权重惩罚项)。

5.4 全局最小与局部极小

- **局部极小**: 邻近点的误差函数值都大于该点。
- **全局最小**: 所有点的误差函数值都大于等于该点。
- **跳出局部极小的方法**: 多组不同初始参数、模拟退火、随机梯度下降、遗传算法等。

5.5 深度学习

- **深度学习**: 深层神经网络, 自动提取多层次特征。
- **典型模型**: 卷积神经网络 (CNN, 擅长图像)、循环神经网络 (RNN, 擅长序列)、深度信念网络 (DBN)。

题目

一、填空题

1. 感知机只能处理_____问题，因为它只有输入层和输出层。
2. BP 算法的核心思想是：将输出误差从_____向_____传播，据此调整各层权重。
3. 标准 BP 每处理_____个样本更新一次权重，累积 BP 处理完_____后更新。
4. 缓解神经网络过拟合的常用策略包括_____和_____。
5. 在训练误差函数中加入权重大小的惩罚项称为_____化。

二、选择题

1. 神经元模型中，权重的作用是：
(A) 决定神经元数量
(B) 表示输入信号的强弱程度
(C) 固定输入信号大小
(D) 存储训练数据
2. 以下哪个问题感知机无法解决？
(A) AND（与）
(B) OR（或）
(C) XOR（异或）
(D) NOT（非）
3. 关于标准 BP 和累积 BP 的对比，正确的是：
(A) 标准 BP 更新更稳定
(B) 累积 BP 更新更快但易震荡
(C) 标准 BP 每样本更新一次
(D) 两种方法完全相同
4. 以下哪种方法不常用于跳出局部极小？
(A) 多组不同初始参数
(B) 模拟退火
(C) 增大学习率
(D) 固定学习率不变

参考答案与解析

一、填空题答案

1. 线性可分
2. 后；前（或：输出层；输入层）
3. 一；全部训练集
4. 早停（early stopping）；正则化
5. 正则

二、选择题答案

1. B（权重表示各输入信号的重要程度）
2. C（异或（XOR）是线性不可分问题）
3. C（标准 BP 每处理一个样本更新一次权重）
4. D（固定学习率不变不能跳出局部极小）
5. C（SVM 不是深度学习的典型模型）

三、简答题参考要点

1. BP 算法流程：
 - (1) 初始化权重和阈值；
 - (2) 输入训练样本，前向传播计算输出；
 - (3) 计算输出与真实值之间的误差；
 - (4) 将误差反向传播，计算各层权重的梯度；
 - (5) 沿梯度方向更新权重和阈值；
 - (6) 重复 (2)–(5) 直到收敛。

缓解过拟合策略：早停（用验证集监控，验证误差不再下降时停止）和正则化（在误差函数中加入权重衰减项，防止权重过大）。

四、概念题答案

1. **激活函数**：在神经元中，对加权输入进行非线性变换的函数，使神经网络具备非线性表达能力。

Sigmoid: $\sigma(x) = \frac{1}{1 + e^{-x}}$ ，输出范围 $(0, 1)$ 。

tanh: $\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$ ，输出范围 $(-1, 1)$ 。

ReLU: $\text{ReLU}(x) = \max(0, x)$ ，输出范围 $[0, \infty)$ 。

ReLU 的优势: (1) 计算简单，无需指数运算；(2) 缓解梯度消失问题（正区间导数为常数 1）；(3) 稀疏激活，使部分神经元输出为 0，提高计算效率。

2. **BP 算法核心思想**：通过前向传播计算输出与真实值的误差，然后将误差从输出层向输入层逐层反向传播，利用链式法则计算各层权重的梯度，沿梯度负方向更新权重。

梯度消失：在使用 Sigmoid 或 tanh 等饱和激活函数的深层网络中，梯度在反向传播

第6章 支持向量机

§ 知识复习

6.1 间隔与支持向量

- 超平面: $f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b = 0$, 其中 $\mathbf{w}$ 为法向量, b 为位移项。
- 间隔 (margin): 两个异类支持向量到超平面的距离之和 $\gamma = \frac{2}{\|\mathbf{w}\|}$ 。
- 支持向量: 使约束条件等号成立的训练样本点, 即距离超平面最近的样本。
- 优化目标: 最大化间隔, 等价于最小化 $\frac{1}{2}\|\mathbf{w}\|^2$, 约束为 $y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$ 。
- 这是一个凸二次规划问题。

6.2 对偶问题

- 用拉格朗日乘子法将原问题转化为对偶问题:

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \quad \alpha_i \geq 0. \end{aligned}$$

- 解得 $\mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i$, 最终模型仅与支持向量有关 (稀疏性)。
- KKT 条件: $\alpha_i \geq 0$, $y_i f(\mathbf{x}_i) - 1 \geq 0$, $\alpha_i (y_i f(\mathbf{x}_i) - 1) = 0$ 。
- SMO 算法: 每次固定其他变量, 选两个 α 优化, 高效求解对偶问题。

6.3 核函数

- 核心思想: 将原始空间映射到更高维的特征空间, 使样本在高维空间中线性可分。
- 核技巧: $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$, 避免直接计算高维内积。
- 常用核函数:
 - 线性核: $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^T \mathbf{x}_j$
 - 多项式核: $\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^T \mathbf{x}_j)^d$

– 高斯核 (RBF): $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma^2}\right)$

- **Mercer 条件**: 对称函数 κ 对应的核矩阵半正定, 则可作为核函数。

6.4 软间隔与正则化

- **软间隔**: 允许部分样本不满足约束, 引入松弛变量 $\xi_i \geq 0$ 。
- 优化目标: $\min \frac{1}{2}\|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i$, C 为惩罚参数。
- **铰链损失 (Hinge Loss)**: $\ell_{\text{hinge}}(z) = \max(0, 1 - z)$ 。
- **正则化**: 结构风险 (正则化项) + 经验风险。 C 控制二者权衡。

6.5 支持向量回归 (SVR)

- 允许预测值与真实值之间有 ϵ 的偏差, 构建 ϵ -间隔带。
- ϵ -不敏感损失函数: $|z|_{\epsilon} = \begin{cases} 0, & |z| \leq \epsilon \\ |z| - \epsilon, & \text{otherwise} \end{cases}$ 。

6.6 核方法

- **表示定理**: 优化问题的解可表示为核函数的线性组合。
- **核化**: 通过核函数将线性学习器拓展为非线性学习器。

题目

一、填空题

1. 支持向量机的基本思想是寻找最大_____的超平面。
2. SVM 中起到决定作用的少数训练样本称为_____。
3. 最大化间隔等价于最小化_____。
4. 核函数的核心思想是将原始空间映射到_____, 使样本在该空间中线性可分。
5. 软间隔 SVM 引入_____ 变量以允许部分样本不满足约束, C 是_____ 参数。
6. SVR 使用 ϵ -_____ 损失函数构建间隔带。

二、选择题

1. SVM 对偶问题中, $\alpha_i > 0$ 对应的样本是:
 - (A) 所有训练样本
 - (B) 支持向量
 - (C) 非支持向量
 - (D) 噪声样本
2. 关于核函数, 以下说法错误的是:
 - (A) 核函数计算高维空间的内积
 - (B) 高斯核的参数 σ 越小, 模型越易过拟合
 - (C) 线性核是多项式核的特例
 - (D) 任何对称函数都可以作为核函数
3. SVM 对偶问题的求解常用算法是:
 - (A) 梯度下降
 - (B) SMO
 - (C) EM 算法
 - (D) K-Means
4. 软间隔 SVM 中, 惩罚参数 C 越大:
 - (A) 对误分类的惩罚越小
 - (B) 模型越可能欠拟合
 - (C) 对误分类的惩罚越大
 - (D) 间隔一定越大

参考答案与解析

一、填空题答案

1. 间隔 (margin)
2. 支持向量
3. $\frac{1}{2}\|\mathbf{w}\|^2$
4. 高维特征空间
5. 松弛; 惩罚
6. 不敏感

二、选择题答案

1. B ($\alpha_i > 0$ 对应的样本是支持向量)
2. D (只有满足 Mercer 条件的对称函数才可作为核函数)
3. B (SMO 算法是求解 SVM 对偶问题的经典算法)
4. C (C 越大, 对误分类的惩罚越大)
5. C (ϵ 越大, 间隔带越宽, 支持向量越少)

三、简答题参考要点

1. 核函数动机: 当样本在原始空间中线性不可分时, 通过映射函数 ϕ 将样本映射到高维特征空间, 使其线性可分。核函数 $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$ 使得我们不需要显式计算高维映射, 直接在原空间通过核函数计算即可, 从而避免了“维数灾难”。
2. 软间隔 SVM 通过引入松弛变量 ξ_i 和惩罚参数 C 来处理噪声和异常点。 C 越大, 对误分类的惩罚越严厉, 模型越倾向于将所有训练样本正确分类 (可能过拟合); C 越小, 对误分类的容忍度越大, 模型更注重最大化间隔 (可能欠拟合)。 C 的选择需要在间隔大小和分类误差之间做权衡。

第7章 贝叶斯分类器

§ 知识复习

7.1 贝叶斯决策论

- 贝叶斯判定准则：为最小化总体风险，选择使条件风险最小的类别标记。
- 最小化分类错误率：对每个样本选择后验概率 $P(c|\mathbf{x})$ 最大的类别。
- 判别式模型：直接对 $P(c|\mathbf{x})$ 建模（如 SVM、逻辑回归）。
- 生成式模型：先对联合概率分布 $P(\mathbf{x}, c)$ 建模，再通过贝叶斯定理计算 $P(c|\mathbf{x})$ 。

7.2 极大似然估计（MLE）

- 频率主义学派认为参数是固定值，通过最大化似然函数来估计。
- 对数似然： $LL(\theta_c) = \sum_{\mathbf{x} \in D_c} \log P(\mathbf{x}|\theta_c)$ 。
- 常用正态分布假设，估计均值和协方差矩阵。

7.3 朴素贝叶斯分类器

- 属性条件独立性假设：对已知类别，假设所有属性相互独立：

$$P(c|\mathbf{x}) \propto P(c) \prod_{i=1}^d P(x_i|c).$$

- 概率估计：
 - 离散属性：频率估计。
 - 连续属性：假设服从正态分布，估计均值和方差。
- 拉普拉斯修正：避免概率为 0，在分子加 1、分母加类别数 N ：

$$\hat{P}(c) = \frac{|D_c| + 1}{|D| + N}.$$

7.4 半朴素贝叶斯分类器

- 放松独立性假设，考虑部分属性之间的依赖关系。
- **ODE（独依赖估计）**：每个属性最多依赖一个其他属性。
- **SPODE**：所有属性依赖同一个超“父属”性。
- **TAN**：基于条件互信息构建最大带权生成树。
- **AODE**：将每个属性作为超父构建 SPODE 并集成。

7.5 贝叶斯网

- **结构**：有向无环图（DAG）表示属性间的依赖关系，条件概率表（CPT）量化依赖强度。
- **典型结构**：同父结构、顺序结构、V 型结构。
- **学习**：结构学习（寻找最优图结构）+ 参数学习（估计 CPT）。
- **推断**：通过已知证据变量推测查询变量的后验概率（如吉布斯采样）。

7.6 EM 算法

- 用于含**隐变量**的参数估计问题。
- **E 步**：基于当前参数计算隐变量的期望（或后验分布）。
- **M 步**：最大化对数似然期望，更新参数。
- 迭代进行 E 步和 M 步直至收敛。

题目

一、填空题

1. 贝叶斯判定准则的目标是使_____ 最小化。
2. 朴素贝叶斯分类器基于_____ 独立性假设。
3. 拉普拉斯修正的目的是避免概率估计值出现_____ 的情况。
4. 半朴素贝叶斯中，ODE 表示每个属性最多依赖_____ 个其他属性。
5. EM 算法用于含有_____ 的参数估计问题，包含_____ 步和_____ 步。

二、选择题

1. 贝叶斯判定准则针对的是：
(A) 最大化后验概率
(B) 最小化条件风险（期望损失）
(C) 最大化似然函数
(D) 最大化先验概率
2. 以下哪项是判别式模型？
(A) 朴素贝叶斯
(B) 贝叶斯网
(C) SVM
(D) 高斯混合模型
3. 拉普拉斯修正的作用是：
(A) 加快训练速度
(B) 避免训练集中未出现的属性值概率为 0
(C) 增强模型非线性
(D) 使模型更复杂
4. SPODE 中所有属性共同依赖的对象称为：
(A) 父属性
(B) 超父属性
(C) 根属性
(D) 叶属性
5. 关于 EM 算法，以下说法正确的是：

参考答案与解析

一、填空题答案

1. 总体风险（期望损失）
2. 属性条件
3. 0
4. 一
5. 隐变量（未观测变量）；E；M

二、选择题答案

1. B（贝叶斯判定准则最小化条件风险）
2. C（SVM 是判别式模型，直接对 $P(c|\mathbf{x})$ 建模）
3. B（拉普拉斯修正防止零概率）
4. B（SPODE 中所有属性依赖同一个超父属性）
5. C（EM 算法处理含隐变量的参数估计问题）

三、计算题答案

1. 色泽属性有 3 个取值（青绿、乌黑、浅白），拉普拉斯修正后：

$$P(\text{色泽} = \text{青绿} | \text{好瓜}) = \frac{60 + 1}{100 + 3} = \frac{61}{103} \approx 0.592.$$

第8章 集成学习

§ 知识复习

8.1 个体与集成

- **集成学习**：通过构建并结合多个学习器来完成学习任务。
- **核心要求**：个体学习器应“好而不同”——既有一定准确率，又有多多样性。
- **集成效果**：个体学习器误差相互独立时，集成可显著降低错误率。
- **两类方法**：
 - **序列化方法**：个体学习器存在强依赖关系，必须串行生成（如 Boosting）。
 - **并行化方法**：个体学习器可同时生成（如 Bagging、随机森林）。

8.2 Boosting

- **工作机制**：先训练一个基学习器，根据其表现调整样本权重，使被错分的样本在后续得到更多关注，再基于调整后的权重训练下一个基学习器，重复进行，最终加权结合。
- **AdaBoost**：最著名的 Boosting 算法，最小化指数损失函数。
- **权重更新**：被正确分类的样本权重减小，被错误分类的样本权重增大。
- **分类器权重**： $\alpha_t = \frac{1}{2} \ln \frac{1-\epsilon_t}{\epsilon_t}$ ，错误率 ϵ_t 越小的分类器权重越大。
- **关注偏差**：Boosting 主要降低偏差（bias）。

8.3 Bagging 与随机森林

- **Bagging**：基于自助采样（bootstrap sampling），每次从原始数据中有放回地抽取 m 个样本训练一个基学习器，重复 T 次，最终投票（分类）或平均（回归）。
- **包外估计**：Bagging 中约 36.8% 的样本未被采到（包外样本），可用于验证。
- **关注方差**：Bagging 主要降低方差（variance）。
- **随机森林（RF）**：Bagging 的扩展，在决策树训练时引入随机属性选择。

- 在 Bagging 自助采样的基础上，每次划分时随机选择 k 个属性（推荐 $k = \log_2 d$ ），再从这 k 个中选最优。
- 引入了样本扰动和属性扰动双重随机性，多样性更强。
- 训练效率通常优于 Bagging。

8.4 结合策略

- 平均法：简单平均、加权平均。
- 投票法：绝对多数投票、相对多数投票、加权投票。
- 学习法：用另一个学习器（次级学习器）来组合（如 Stacking）。

8.5 多样性

- 误差-分歧分解：集成泛化误差 = 个体平均泛化误差 - 个体分歧。
- 多样性增强：数据样本扰动、输入属性扰动、输出表示扰动、算法参数扰动。

题目

一、填空题

1. 集成学习要求个体学习器应好“而不同”，即既要有一定的_____，又要有_____。
2. AdaBoost 中，被错误分类的样本权重会_____，被正确分类的样本权重会_____。
3. Bagging 基于_____ 采样方法，原始数据中约_____ % 的样本不会出现在训练集中。
4. 随机森林在 Bagging 的基础上，额外引入了_____ 扰动。
5. Boosting 主要关注降低_____ (bias) ， Bagging 主要关注降低_____ (variance)。

二、选择题

1. 集成学习中，个体学习器应满足的条件是：
(A) 完全相同
(B) 好而不同
(C) 越复杂越好
(D) 完全独立于数据
2. AdaBoost 中分类器权重 α_t 的计算公式为：
(A) $\alpha_t = \frac{1}{2} \ln \frac{\epsilon_t}{1-\epsilon_t}$
(B) $\alpha_t = \frac{1}{2} \ln \frac{1-\epsilon_t}{\epsilon_t}$
(C) $\alpha_t = \frac{1-\epsilon_t}{\epsilon_t}$
(D) $\alpha_t = \epsilon_t$
3. 以下哪项不是 Bagging 的特点？
(A) 使用自助采样
(B) 基学习器可并行训练
(C) 主要关注偏差
(D) 包外样本可用于验证
4. 随机森林中，属性选择时推荐的 k 值（特征子集大小）为：
(A) $k = d$ （全部特征）
(B) $k = \sqrt{d}$
(C) $k = \log_2 d$

参考答案与解析

一、填空题答案

1. 准确率；多样性
2. 增大；减小
3. 自助 (bootstrap); 36.8
4. 属性 (特征)
5. 偏差；方差

二、选择题答案

1. B (集成学习要求个体学习器好“而不同”)
2. B ($\alpha_t = \frac{1}{2} \ln \frac{1-\epsilon_t}{\epsilon_t}$)
3. C (Bagging 主要降低方差, Boosting 主要降低偏差)
4. C (推荐 $k = \log_2 d$, 西瓜书也提到 $k = \log_2 d$ 的推荐值)
5. B (集成泛化误差 = 个体平均泛化误差 - 分歧)

三、计算题答案

1. $\alpha_t = \frac{1}{2} \ln \frac{1-0.25}{0.25} = \frac{1}{2} \ln 3 \approx 0.549$ 。

第9章 聚类

§ 知识复习

9.1 聚类任务

- **聚类**：无监督学习，将样本划分为若干个不相交的簇（cluster）。
- **目标**：簇内相似度高、簇间相似度低。
- **距离度量**：闵可夫斯基距离（ $p = 2$ 为欧氏距离、 $p = 1$ 为曼哈顿距离）；VDM（处理无序属性）。

9.2 性能度量

- **外部指标**：基于已知的参考模型评估（如 Jaccard 系数、FM 指数、Rand 指数）。
- **内部指标**：不依赖参考模型，直接考察聚类结果（如 DBI 指数——越小越好；DI 指数——越大越好）。

9.3 原型聚类

- **k 均值 (K-Means)**：最小化平方误差 $\sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|_2^2$ ，迭代更新簇中心。
- **学习向量量化 (LVQ)**：利用样本类别信息辅助聚类，原型向量通过竞争学习调整。
- **高斯混合聚类 (GMM)**：假设数据由多个高斯分布混合生成，用 EM 算法求解。

9.4 密度聚类

- **DBSCAN**：基于一组邻域参数（ ϵ , MinPts）刻画样本分布的紧密程度。
- 核心对象、密度直达、密度可达、密度相连等概念。
- 能发现任意形状的簇，对噪声鲁棒。

9.5 层次聚类

- **AGNES (自底向上凝聚)**：每个样本初始为一个簇，迭代合并最近的两个簇。
- **簇间距离**：最小距离（单链接）、最大距离（全链接）、平均距离（均链接）。

- 结果可用树状图（dendrogram）展示。

题目

一、填空题

1. 聚类属于_____学习, 目标是将样本划分为若干个_____的簇。
2. DBI 指数越_____越好, DI 指数越_____越好。
3. K-Means 算法的优化目标是_____误差。
4. DBSCAN 算法需要用户指定的两个参数是_____和_____。
5. AGNES 是一种_____的层次聚类算法, 使用_____图展示聚类结果。

二、选择题

1. K-Means 算法的目标函数是:
(A) 最大化类间距离
(B) 最小化平方误差
(C) 最大化似然函数
(D) 最小化熵
2. 高斯混合聚类的参数估计常用算法是:
(A) 梯度下降
(B) EM 算法
(C) 随机梯度下降
(D) BP 算法
3. 当闵可夫斯基距离参数 $p = 2$ 时, 得到的是:
(A) 曼哈顿距离
(B) 欧氏距离
(C) 切比雪夫距离
(D) 余弦距离
4. DBSCAN 中, 核心对象定义的条件是:
(A) ϵ -邻域内样本数 $\geq \text{MinPts}$
(B) ϵ -邻域内样本数 $< \text{MinPts}$
(C) 样本位于簇中心
(D) 样本密度最小
5. AGNES 中, 使用不同簇间距离度量得到不同变体, 其中全“链接对”应:

参考答案与解析

一、填空题答案

1. 无监督；不相交
2. 小；大
3. 平方
4. ϵ （邻域半径）；MinPts（密度阈值）
5. 自底向上凝聚（凝聚式）；树状（dendrogram）

二、选择题答案

1. B（K-Means 最小化平方误差）
2. B（高斯混合聚类用 EM 算法求解）
3. B（ $p = 2$ 时为欧氏距离）
4. A（核心对象的 ϵ -邻域内至少包含 MinPts 个样本）
5. B（全链接使用簇间最远样本对的距离）

三、计算题答案

1. 初始簇中心： $\mu_1 = (1, 2)$ （A 点）， $\mu_2 = (5, 4)$ （C 点）。
计算各点到两中心的欧氏距离：
A 到 μ_1 距离 0，到 μ_2 距离 5——A $\in$ 簇 1；
B(2, 1) 到 μ_1 ： $\sqrt{2} \approx 1.414$ ，到 μ_2 ： $\sqrt{18} \approx 4.243$ ——B $\in$ 簇 1；
C(5, 4) 到 μ_1 ：5，到 μ_2 ：0——C $\in$ 簇 2；
D(6, 3) 到 μ_1 ： $\sqrt{26} \approx 5.099$ ，到 μ_2 ： $\sqrt{2} \approx 1.414$ ——D $\in$ 簇 2；
E(7, 5) 到 μ_1 ： $\sqrt{45} \approx 6.708$ ，到 μ_2 ： $\sqrt{5} \approx 2.236$ ——E $\in$ 簇 2。
簇 1： $\{A, B\}$ ，新中心 $\mu'_1 = ((1 + 2)/2, (2 + 1)/2) = (1.5, 1.5)$ ；
簇 2： $\{C, D, E\}$ ，新中心 $\mu'_2 = ((5 + 6 + 7)/3, (4 + 3 + 5)/3) = (6, 4)$ 。

第 10 章 降维与度量学习

§ 知识复习

10.1 k 近邻学习

- **kNN**: 懒惰学习的代表, 训练阶段开销为零, 预测时找到最近的 k 个训练样本进行投票。
- **性质**: 最近邻分类器的泛化误差不超过贝叶斯最优分类器误差的两倍。
- 在高维空间中, kNN 面临“维数灾难”——需要大量训练样本才能达到好的效果。

10.2 低维嵌入

- **维数灾难**: 随着维度的增加, 数据变得稀疏, 距离度量失去意义。
- **降维**: 通过数学变换将高维数据映射到低维空间, 保留关键信息。
- **MDS (多维缩放)**: 保持样本间的距离不变, 将数据投影到低维空间。

10.3 主成分分析 (PCA)

- **目标**: 找到一个超平面, 使样本在超平面上的投影具有最大方差 (或最小重构误差)。
- **解法**: 对协方差矩阵 $\mathbf{X}\mathbf{X}^T$ 进行特征值分解, 取前 d' 个最大特征值对应的特征向量构成投影矩阵。
- **两者等价**: 最大投影方差 $\Leftrightarrow$ 最小重构距离。
- **主成分数目选择**: 通过保留的方差比例 (如 95%) 确定。

10.4 核化 PCA (KPCA)

- 用核技巧将 PCA 扩展到非线性: 先通过核函数映射到高维特征空间, 再在该空间做 PCA。
- 计算核矩阵的特征值分解。

10.5 流形学习

- **流形假设**: 高维数据实际上位于一个低维流形上。
- **Isomap**: 用近邻图上的最短路径 (Dijkstra/Floyd) 近似测地距离, 再用 MDS 降维。
- **LLE (局部线性嵌入)**: 假设局部邻域内数据保持线性关系, 先求局部重构权重, 再保持权重不变求低维嵌入。

10.6 度量学习

- 学习一个距离度量 (马氏距离), 使同类样本距离近、异类样本距离远。
- **马氏距离**: $\text{dist}(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{(\mathbf{x}_i - \mathbf{x}_j)^T \mathbf{M} (\mathbf{x}_i - \mathbf{x}_j)}$, $\mathbf{M}$ 半正定。
- **NCA (近邻成分分析)**: 通过优化留一法 kNN 准确率来学习距离度量。

题目

一、填空题

1. kNN 算法属于_____ 学习 (lazy learning) , 其训练阶段开销为_____。
2. 最近邻分类器的泛化误差不超过贝叶斯最优分类器误差的_____ 倍。
3. PCA 的优化目标是最大化_____ 或最小化_____。
4. 流形学习假设高维数据实际上位于一个_____ 上。
5. Isomap 在近邻图上使用_____ 或_____ 算法计算最短路径近似测地距离。
6. 度量学习中, 马氏距离矩阵 $\mathbf{M}$ 必须满足_____ 定的条件。

二、选择题

1. MDS 的核心思想是:
(A) 保持方差最大
(B) 保持样本间距离不变
(C) 最小化重构误差
(D) 最大化类间距离
2. PCA 的优化目标可等价地写为:
(A) $\max \|\mathbf{X}\mathbf{W}\|_F^2$
(B) $\min \|\mathbf{X}\mathbf{W}\|_F^2$
(C) $\max \|\mathbf{X} - \mathbf{W}\mathbf{W}^T\mathbf{X}\|_F^2$
(D) $\min \|\mathbf{W}^T\mathbf{W} - \mathbf{I}\|_F^2$
3. Isomap 中, 计算测地距离时使用的是什么路径?
(A) 欧氏距离
(B) 最短路径
(C) 最长路径
(D) 随机路径
4. KPCA 的核心技术是:
(A) 直接降维
(B) 核技巧
(C) 流形假设
(D) 稀疏表示

参考答案与解析

一、填空题答案

1. 懒惰 (lazy); 零
2. 两 (2)
3. 投影方差; 重构误差
4. 低维流形
5. Dijkstra; Floyd
6. 半正

二、选择题答案

1. B (MDS 保持样本间距离不变)
2. A ($\max \|\mathbf{X}\mathbf{W}\|_F^2$ 等价于最大化投影方差)
3. B (Isomap 用近邻图上的最短路径近似测地距离)
4. B (KPCA 使用核技巧实现非线性降维)
5. B (NCA 通过优化留一法 kNN 准确率学习度量)

三、简答题参考要点

1. PCA 求解过程:
 - (1) 对所有样本进行中心化 (减均值);
 - (2) 计算样本的协方差矩阵;
 - (3) 对协方差矩阵进行特征值分解;
 - (4) 取前 d' 个最大特征值对应的特征向量构成投影矩阵;
 - (5) 将原始数据投影到这些特征向量上得到降维结果。

等价性: 投影后的方差为 $\mathbf{w}^T \mathbf{X}^T \mathbf{X} \mathbf{w}$, 重构误差为 $\|\mathbf{X} - \mathbf{X} \mathbf{w} \mathbf{w}^T\|_F^2$ 。通过推导可证明最大化 $\mathbf{w}^T \mathbf{X}^T \mathbf{X} \mathbf{w}$ 等价于最小化重构误差。

第 11 章 特征选择与稀疏学习

§ 知识复习

11.1 子集搜索与评价

- **特征选择**: 从 d 个特征中选择一个子集, 去除无关和冗余特征, 缓解维数灾难。
- **子集搜索**: 前向搜索、后向搜索、双向搜索。
- **子集评价**: 信息增益、相关性、距离度量等。

11.2 过滤式选择 (Filter)

- 先对数据集进行特征选择, 再训练学习器。
- **Relief**: 统计方法, 对每个特征计算统计量, 度量其区分能力。
 - 对每个样本找同类最近邻和异类最近邻。
 - 特征质量度量: 同类近邻距离越小越好, 异类近邻距离越大越好。
- **Relief-F**: Relief 扩展到多分类问题。

11.3 包裹式选择 (Wrapper)

- 将学习器的性能作为特征子集的评价标准。
- **LVW**: 在拉斯维加斯方法框架下随机搜索特征子集, 以交叉验证误差为评价标准。
- 计算开销大, 但通常比过滤式选择效果更好。

11.4 嵌入式选择 (Embedded)

- 特征选择与学习器训练过程融为一体。
- **岭回归 (L_2 正则化)**: $\min \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \lambda \|\mathbf{w}\|_2^2$ 。
- **LASSO (L_1 正则化)**: $\min \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \lambda \|\mathbf{w}\|_1$ 。
- LASSO 易产生稀疏解 (很多特征权重为 0), 实现自动特征选择。
- **近端梯度下降 (PGD)**: 求解 LASSO 的常用方法。

11.5 稀疏表示与字典学习

- **稀疏表示**：将样本表示为稀疏的线性组合（大部分系数为 0）。
- **字典学习**：学习一个字典矩阵 B ，使每个样本 $x \approx B\alpha$ ，且 α 稀疏。
- **优化交替进行**：固定字典求稀疏编码，固定稀疏编码更新字典。

11.6 压缩感知

- 从少量采样信号中恢复原始信号，利用信号的稀疏性。
- **限制等距性 (RIP)**：保证信号可精确恢复的条件。
- 将 L_0 范数最小化 (NP 难) 松弛为 L_1 范数最小化 (凸优化) 求解。

题目

一、填空题

1. 特征选择方法可分为过滤式、_____ 式和_____ 式三类。
2. Relief 是一种_____ 式特征选择方法，它基于_____ 方法评估特征。
3. LVW 算法使用_____ 框架随机搜索特征子集。
4. LASSO 回归通过_____ 范数正则化实现自动特征选择，产生_____ 解。
5. 压缩感知中，将 NP 难的 L_0 范数最小化松弛为_____ 范数最小化求解。

二、选择题

1. 以下哪个方法属于过滤式特征选择？
(A) LVW
(B) LASSO
(C) Relief
(D) PCA
2. LASSO 回归的目标函数是：
(A) $\min \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \lambda \|\mathbf{w}\|_2^2$
(B) $\min \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \lambda \|\mathbf{w}\|_1$
(C) $\min \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_1 + \lambda \|\mathbf{w}\|_2^2$
(D) $\min \frac{1}{2} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \lambda \|\mathbf{w}\|_0$
3. Relief-F 的扩展方向是：
(A) 处理缺失值
(B) 处理多分类问题
(C) 处理连续值
(D) 处理高维数据
4. 压缩感知中，信号重建的关键条件是信号的：
(A) 稠密性
(B) 稀疏性
(C) 连续性
(D) 周期性

参考答案与解析

一、填空题答案

1. 包裹 (Wrapper); 嵌入 (Embedded)
2. 过滤 (Filter); 统计
3. 拉斯维加斯 (Las Vegas)
4. L_1 (L1); 稀疏
5. L_1 (L1)

二、选择题答案

1. C (Relief 是过滤式特征选择, LVW 包裹式, LASSO 嵌入式, PCA 无监督降维)
2. B (LASSO 是 L_1 正则化的最小二乘)
3. B (Relief-F 将 Relief 扩展到多分类问题)
4. B (压缩感知利用信号的稀疏性进行重建)
5. B (字典学习交替进行稀疏编码和字典更新)

三、简答题参考要点

1. 比较三种特征选择方法:

过滤式: 先选择特征再训练, 与学习器无关, 计算效率高, 但可能选不到对特定学习器最优的特征子集。

包裹式: 以学习器性能为评价标准, 效果通常更好, 但需要反复训练学习器, 计算开销大。

嵌入式: 特征选择与训练过程融合, 效率介于过滤式和包裹式之间, 能利用学习器的内部机制。

第12章 计算题专项练习

说明：本练习按7大计算考点分类，每个考点1-2题，共12题。满分100分，每题分值标注于题号后。

考点一：混淆矩阵与性能指标（第2章）[共15分]

题1（8分）某二分类模型对300个样本的预测结果如下：

	预测正例	预测反例
真实正例	120	30
真实反例	40	110

求：(1) 准确率 Accuracy；(2) 查准率 Precision；(3) 查全率 Recall；(4) F_1 值；(5) 假正率 FPR。（各2分）

题2（7分）某疾病检测模型对500人进行筛查，结果如下：

	预测患病	预测健康
实际患病	45	5
实际健康	20	430

求：(1) 真正率 TPR；(2) 真负率 TNR（特异性）；(3) 查准率 Precision；(4) F_1 值。

考点二：信息熵 / 信息增益 / 基尼指数（第4章）[共18分]

题3（9分）数据集 D 有16个样本（8正8反），已知 $\text{Ent}(D) = 1.000$ 。用属性“色泽”划分得三个子集：

色泽	样本数	分布（正，反）
青绿	6	(4,2)
乌黑	6	(3,3)
浅白	4	(1,3)

已知各子集信息熵：

$$\text{Ent}(D^{\text{青绿}}) = 0.918, \quad \text{Ent}(D^{\text{乌黑}}) = 1.000, \quad \text{Ent}(D^{\text{浅白}}) = 0.811$$

求：(1) 属性“色泽”的信息增益 $\text{Gain}(D, \text{色泽})$ ；(2) 属性“色泽”的固有值 $\text{IV}(\text{色泽})$ ；(3) 增益率 Gain_ratio 。

题 4 (9 分) 一个二分类数据集 D 有 10 个样本 (6 正 4 反)。用编号为 a 的属性划分后得到两个分支：

分支	样本数	分布 (正, 反)
D^1	6	(5,1)
D^2	4	(1,3)

(1) 计算 $\text{Ent}(D)$ ；(2) 计算各分支的信息熵 $\text{Ent}(D^1)$ 和 $\text{Ent}(D^2)$ ；(3) 计算信息增益 $\text{Gain}(D, a)$ 。

已知： $\log_2 1 = 0$, $\log_2 2 = 1$, $\log_2 3 \approx 1.585$, $\log_2 5 \approx 2.322$

考点三：最小二乘法拟合线性回归 (第 3 章) [共 16 分]

题 5 (8 分) 给定以下 4 个观测点：

$$(1, 2.2), (2, 4.1), (3, 5.9), (4, 8.0)$$

用最小二乘法拟合一元线性回归模型 $y = wx + b$, 求参数 w 和 b 。

提示： $w = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$, $b = \bar{y} - w\bar{x}$ 。

题 6 (8 分) 已知某组数据满足： $\bar{x} = 3$, $\bar{y} = 5$, 且

$$\sum_{i=1}^5 (x_i - \bar{x})(y_i - \bar{y}) = 14, \quad \sum_{i=1}^5 (x_i - \bar{x})^2 = 7$$

(1) 求 w 和 b ；(2) 当 $x = 6$ 时，预测 $\hat{y}$ 的值。

考点四：AdaBoost 分类器权重 (第 8 章) [共 12 分]

题 7 (6 分) AdaBoost 某轮迭代中，弱分类器 h_t 的加权错误率为 $\epsilon_t = 0.25$ 。

(1) 计算该分类器的权重 α_t ；(2) 若下一轮中某样本被上一轮分错，其权重调整的方向是什么？(乘 $\exp(\alpha_t)$ 还是 $\exp(-\alpha_t)$ ？为什么？)

题 8 (6 分) 回答以下关于 AdaBoost 的问题：

(1) 若 $\epsilon_t = 0.5$, 则 α_t 等于多少？这说明了什么？(2) 若 $\epsilon_t = 0.7$, 该如何处理？请写出具体做法。

考点五：K-Means 聚类迭代（第 9 章）[共 15 分]

题 9（15 分） 给定以下 6 个二维数据点：

$$A(0,2), \quad B(0,0), \quad C(1,0), \quad D(5,0), \quad E(5,2), \quad F(4,3)$$

设 $k = 2$ ，初始簇中心为 $m_1 = (0,0)$ ， $m_2 = (5,2)$ 。

(1) 计算每个点到两个中心的欧氏距离，并分配所属簇；（6 分）(2) 根据分配结果，更新两个簇的中心；（6 分）(3) 写出更新后的新中心坐标。（3 分）

考点六：朴素贝叶斯 & 拉普拉斯修正（第 7 章）[共 20 分]

题 10（20 分） 本题覆盖无修正（极大似然估计）和拉普拉斯平滑修正两种场景。

给定二分类训练数据集，标签为“好瓜”，取值 {是, 否}；包含 2 个离散特征：

- 特征 1 “色泽”：取值 {青绿, 乌黑, 浅白}，共 3 种
- 特征 2 “触感”：取值 {硬滑, 软粘}，共 2 种

训练样本详情：

编号	色泽	触感	好瓜
1	青绿	硬滑	是
2	乌黑	硬滑	是
3	乌黑	软粘	是
4	青绿	软粘	否
5	浅白	硬滑	否
6	浅白	软粘	否

现有测试样本：色泽 = 浅白，触感 = 硬滑。

- (1) **无拉普拉斯修正（极大似然估计）**：计算类先验概率、各特征条件概率，用朴素贝叶斯判断测试样本类别；（10 分）
- (2) **拉普拉斯修正（ $\lambda = 1$ ）**：采用拉普拉斯平滑重新计算上述概率，再次判断样本类别，并说明修正的作用。（10 分）

考点七：SVD 手撕计算 [共 16 分]

题 11（6 分） ——能量保留率对一张 200×200 的灰度图像进行 SVD 分解，前 8 个奇异值为：

$$s = [800, 400, 200, 100, 50, 30, 15, 5]$$

(1) 取前 $k = 3$ 个奇异值时的能量保留百分比；(3 分) (2) 若要保留至少 95% 的能量，最少需要取多少个奇异值？(3 分)

题 12 (10 分) ——手算 SVD 分解求矩阵

$$A = \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix}$$

的奇异值分解 $A = U\Sigma V^T$ ，写出 U 、 Σ 、 V 的具体值。

提示步骤：

1. 计算 $A^T A$ 的特征值和特征向量 $\rightarrow$ 得到 V 和 Σ ;
2. 通过 $u_i = \frac{1}{\sigma_i} A v_i$ 求左奇异向量 $\rightarrow$ 得到 U 。

参考答案与解析

考点一：混淆矩阵与性能指标

题 1

由混淆矩阵得：TP=120, FN=30, FP=40, TN=110, N=300

$$(1) \text{Accuracy} = \frac{TP + TN}{N} = \frac{120 + 110}{300} = \frac{230}{300} \approx 0.767$$

$$(2) \text{Precision} = \frac{TP}{TP + FP} = \frac{120}{160} = 0.75$$

$$(3) \text{Recall} = \frac{TP}{TP + FN} = \frac{120}{150} = 0.8$$

$$(4) F_1 = \frac{2 \times P \times R}{P + R} = \frac{2 \times 0.75 \times 0.8}{0.75 + 0.8} = \frac{1.2}{1.55} \approx 0.774$$

$$(5) \text{FPR} = \frac{FP}{FP + TN} = \frac{40}{150} \approx 0.267$$

题 2

TP=45, FN=5, FP=20, TN=430

$$(1) \text{TPR} = \frac{TP}{TP + FN} = \frac{45}{45 + 5} = \frac{45}{50} = 0.9$$

$$(2) \text{TNR} = \frac{TN}{FP + TN} = \frac{430}{450} \approx 0.956$$

$$(3) \text{ Precision} = \frac{45}{45+20} = \frac{45}{65} \approx 0.692$$

$$(4) F_1 = \frac{2 \times 0.692 \times 0.9}{0.692 + 0.9} \approx \frac{1.246}{1.592} \approx 0.782$$

考点二：信息熵 / 信息增益 / 基尼指数

题 3

(1) 信息增益：

$$\begin{aligned} \text{Gain}(D, \text{色泽}) &= \text{Ent}(D) - \sum_v \frac{|D^v|}{|D|} \text{Ent}(D^v) \\ &= 1.000 - \left(\frac{6}{16} \times 0.918 + \frac{6}{16} \times 1.000 + \frac{4}{16} \times 0.811 \right) \\ &= 1.000 - (0.344 + 0.375 + 0.203) = 1.000 - 0.922 = 0.078 \end{aligned}$$

(2) 固有值：

$$\begin{aligned} \text{IV}(\text{色泽}) &= - \sum_v \frac{|D^v|}{|D|} \log_2 \frac{|D^v|}{|D|} \\ &= - \left(\frac{6}{16} \log_2 \frac{6}{16} + \frac{6}{16} \log_2 \frac{6}{16} + \frac{4}{16} \log_2 \frac{4}{16} \right) \\ &= - (0.375 \times (-1.415) + 0.375 \times (-1.415) + 0.25 \times (-2)) \\ &= -(-0.531 - 0.531 - 0.5) = 1.562 \end{aligned}$$

$$(3) \text{ Gain_ratio} = \frac{0.078}{1.562} \approx 0.050$$

题 4

$$\begin{aligned} (1) \text{ Ent}(D) &= -\frac{6}{10} \log_2 \frac{6}{10} - \frac{4}{10} \log_2 \frac{4}{10} \\ &= -0.6 \times (-0.737) - 0.4 \times (-1.322) = 0.442 + 0.529 = 0.971 \end{aligned}$$

$$\begin{aligned} (2) \text{ Ent}(D^1) &= -\frac{5}{6} \log_2 \frac{5}{6} - \frac{1}{6} \log_2 \frac{1}{6} \\ &= -0.833 \times (-0.263) - 0.167 \times (-2.585) = 0.219 + 0.432 = 0.650 \end{aligned}$$

$$\begin{aligned} \text{Ent}(D^2) &= -\frac{1}{4} \log_2 \frac{1}{4} - \frac{3}{4} \log_2 \frac{3}{4} \\ &= -0.25 \times (-2) - 0.75 \times (-0.415) = 0.5 + 0.311 = 0.811 \end{aligned}$$

$$\begin{aligned} (3) \text{ Gain}(D, a) &= 0.971 - \left(\frac{6}{10} \times 0.650 + \frac{4}{10} \times 0.811 \right) \\ &= 0.971 - (0.390 + 0.324) = 0.971 - 0.714 = 0.257 \end{aligned}$$

考点三：最小二乘法拟合线性回归

题 5

$$\bar{x} = \frac{1+2+3+4}{4} = 2.5, \quad \bar{y} = \frac{2.2+4.1+5.9+8.0}{4} = 5.05$$

x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$
1	2.2	-1.5	-2.85	4.275
2	4.1	-0.5	-0.95	0.475
3	5.9	0.5	0.85	0.425
4	8.0	1.5	2.95	4.425

$$\sum (x_i - \bar{x})(y_i - \bar{y}) = 4.275 + 0.475 + 0.425 + 4.425 = 9.6$$

$$\sum (x_i - \bar{x})^2 = (-1.5)^2 + (-0.5)^2 + 0.5^2 + 1.5^2 = 2.25 + 0.25 + 0.25 + 2.25 = 5.0$$

$$w = \frac{9.6}{5.0} = 1.92, \quad b = 5.05 - 1.92 \times 2.5 = 5.05 - 4.8 = 0.25$$

因此回归方程为 $\hat{y} = 1.92x + 0.25$ 。

题 6

$$(1) w = \frac{14}{7} = 2, \quad b = 5 - 2 \times 3 = -1$$

$$(2) \hat{y} = 2 \times 6 - 1 = 11$$

考点四：AdaBoost 分类器权重

题 7

$$(1) \alpha_t = \frac{1}{2} \ln \frac{1-\epsilon_t}{\epsilon_t} = \frac{1}{2} \ln \frac{0.75}{0.25} = \frac{1}{2} \ln 3 \approx \frac{1}{2} \times 1.099 = 0.549$$

(2) 被分错的样本权重应乘 $\exp(\alpha_t)$ 。因为 $\alpha_t > 0$, $\exp(\alpha_t) > 1$, 使分错样本的权重增大, 下一轮基学习器会更加关注这些难分样本。分对样本则乘 $\exp(-\alpha_t) < 1$, 权重减小。

题 8

(1) $\epsilon_t = 0.5$ 时:

$$\alpha_t = \frac{1}{2} \ln \frac{0.5}{0.5} = \frac{1}{2} \ln 1 = 0$$

这说明该分类器的效果等同随机猜测, 在集成中贡献为 0, 应丢弃此分类器。

(2) $\epsilon_t = 0.7 > 0.5$, 说明分类器效果比随机猜测还差。应当将分类器的预测取反, 此时等效于 $\epsilon'_t = 1 - 0.7 = 0.3$, 再计算 $\alpha_t = \frac{1}{2} \ln \frac{0.7}{0.3} \approx 0.424$ 。

考点五：K-Means 聚类迭代

题 9

(1) 各点到两中心的欧氏距离：

先给每个点到 $m_1 = (0, 0)$ 的距离平方：

$$d_A^2 = (0 - 0)^2 + (2 - 0)^2 = 4 \Rightarrow d_A = 2.000$$

$$d_B^2 = 0 \Rightarrow d_B = 0$$

$$d_C^2 = 1 \Rightarrow d_C = 1$$

$$d_D^2 = 25 \Rightarrow d_D = 5$$

$$d_E^2 = 25 + 4 = 29 \Rightarrow d_E \approx 5.385$$

$$d_F^2 = 16 + 9 = 25 \Rightarrow d_F = 5$$

到 $m_2 = (5, 2)$ 的距离平方：

$$d_A^2 = 25 + 0 = 25 \Rightarrow d_A \approx 5.000$$

$$d_B^2 = 25 + 4 = 29 \Rightarrow d_B \approx 5.385$$

$$d_C^2 = 16 + 4 = 20 \Rightarrow d_C \approx 4.472$$

$$d_D^2 = 0 + 4 = 4 \Rightarrow d_D = 2$$

$$d_E^2 = 0 \Rightarrow d_E = 0$$

$$d_F^2 = 1 + 1 = 2 \Rightarrow d_F \approx 1.414$$

距离较近者归入该簇：

$$C_1 = \{A, B, C\}, \quad C_2 = \{D, E, F\}$$

(2) 更新簇中心：

$$m'_1 = \left(\frac{0 + 0 + 1}{3}, \frac{2 + 0 + 0}{3} \right) = \left(\frac{1}{3}, \frac{2}{3} \right) \approx (0.333, 0.667)$$

$$m'_2 = \left(\frac{5 + 5 + 4}{3}, \frac{0 + 2 + 3}{3} \right) = \left(\frac{14}{3}, \frac{5}{3} \right) \approx (4.667, 1.667)$$

考点六：朴素贝叶斯 & 拉普拉斯修正

题 10

基础统计量： $|D| = 6$ ，类别总数 $N = 2$ （是/否）， $|D_{\text{是}}| = 3$ ， $|D_{\text{否}}| = 3$ 。色泽取值数 $S_1 = 3$ ，触感取值数 $S_2 = 2$ 。

情况 1：无拉普拉斯修正（极大似然估计）

类先验概率：

$$P(\text{是}) = \frac{3}{6} = 0.5, \quad P(\text{否}) = \frac{3}{6} = 0.5$$

特征条件概率：

好瓜 = 是：

$$P(\text{青绿}|\text{是}) = \frac{1}{3}, \quad P(\text{乌黑}|\text{是}) = \frac{2}{3}, \quad P(\text{浅白}|\text{是}) = \frac{0}{3} = 0$$

$$P(\text{硬滑}|\text{是}) = \frac{2}{3}, \quad P(\text{软粘}|\text{是}) = \frac{1}{3}$$

好瓜 = 否：

$$P(\text{青绿}|\text{否}) = \frac{1}{3}, \quad P(\text{乌黑}|\text{否}) = \frac{0}{3} = 0, \quad P(\text{浅白}|\text{否}) = \frac{2}{3}$$

$$P(\text{硬滑}|\text{否}) = \frac{1}{3}, \quad P(\text{软粘}|\text{否}) = \frac{2}{3}$$

分类（比较后验概率分子，分母相同）：

$$P(\text{是})P(\text{浅白}|\text{是})P(\text{硬滑}|\text{是}) = 0.5 \times 0 \times \frac{2}{3} = 0$$

$$P(\text{否})P(\text{浅白}|\text{否})P(\text{硬滑}|\text{否}) = 0.5 \times \frac{2}{3} \times \frac{1}{3} = \frac{1}{9} \approx 0.111$$

结论：判为坏瓜（否）。但好瓜后验被直接判为 0——仅因训练集中好瓜类没出现过浅白，属“一票否决”，易因样本稀疏误判。

情况 2：拉普拉斯修正（ $\lambda = 1$ ）

修正公式： $P(c) = \frac{|D_c| + 1}{|D| + N}$, $P(x_i|c) = \frac{|D_{c,x_i}| + 1}{|D_c| + S_i}$ 。

修正后的类先验：

$$P(\text{是}) = \frac{3+1}{6+2} = \frac{4}{8} = 0.5, \quad P(\text{否}) = \frac{3+1}{6+2} = \frac{4}{8} = 0.5$$

修正后的条件概率：

好瓜 = 是：

$$P(\text{青绿}|\text{是}) = \frac{1+1}{3+3} = \frac{2}{6} = \frac{1}{3}, \quad P(\text{乌黑}|\text{是}) = \frac{2+1}{3+3} = \frac{3}{6} = \frac{1}{2}$$

$$P(\text{浅白}|\text{是}) = \frac{0+1}{3+3} = \frac{1}{6} \text{ (原 0 概率被修正为小概率)}$$

$$P(\text{硬滑}|\text{是}) = \frac{2+1}{3+2} = \frac{3}{5}, \quad P(\text{软粘}|\text{是}) = \frac{1+1}{3+2} = \frac{2}{5}$$

好瓜 = 否：

$$P(\text{青绿}|\text{否}) = \frac{1+1}{3+3} = \frac{1}{3}, \quad P(\text{乌黑}|\text{否}) = \frac{0+1}{3+3} = \frac{1}{6}$$

$$P(\text{浅白}|\text{否}) = \frac{2+1}{3+3} = \frac{1}{2}$$

$$P(\text{硬滑}|\text{否}) = \frac{1+1}{3+2} = \frac{2}{5}, \quad P(\text{软粘}|\text{否}) = \frac{2+1}{3+2} = \frac{3}{5}$$

分类:

$$P(\text{是})P(\text{浅白}|\text{是})P(\text{硬滑}|\text{是}) = \frac{4}{8} \times \frac{1}{6} \times \frac{3}{5} = \frac{1}{20} = 0.05$$

$$P(\text{否})P(\text{浅白}|\text{否})P(\text{硬滑}|\text{否}) = \frac{4}{8} \times \frac{1}{2} \times \frac{2}{5} = \frac{1}{10} = 0.1$$

结论: 仍判为坏瓜 (否), 但好瓜概率不再是 0, 而是合理的小概率值, 避免了零概率 “一票否决”。

核心总结:

1. 拉普拉斯修正同时作用于类先验概率和特征条件概率, 防止零概率绝对化。
2. 训练样本量越大, 修正影响越小; 样本越稀疏、特征取值越多, 修正作用越明显。
3. 修正不改变概率相对大小 (本例仍是坏瓜概率更高), 但估计更平滑。

考点七: SVD 手撕计算

题 11

奇异值总和: $S_{\text{total}} = 800 + 400 + 200 + 100 + 50 + 30 + 15 + 5 = 1600$

(1) $k = 3$:

$$\frac{800 + 400 + 200}{1600} = \frac{1400}{1600} = 87.5\%$$

(2) 前 4 个占比: $\frac{1400 + 100}{1600} = \frac{1500}{1600} = 93.75\% < 95\%$ 前 5 个占比: $\frac{1500 + 50}{1600} = \frac{1550}{1600} = 96.875\% > 95\%$ 因此至少需要 $k = 5$ 。

题 12

$$A = \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix}$$

$$\text{Step 1: } A^T A = \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix} \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix} = \begin{pmatrix} 4 & 0 \\ 0 & 9 \end{pmatrix}$$

$$\text{Step 2: 特征值 } \lambda_1 = 9, \lambda_2 = 4 \text{ (按降序排列) 奇异值 } \sigma_1 = \sqrt{9} = 3, \sigma_2 = \sqrt{4} = 2 \quad \Sigma = \begin{pmatrix} 3 & 0 \\ 0 & 2 \end{pmatrix}$$

$$\text{Step 3: 求 } V \text{ (} A^T A \text{ 的特征向量, 按奇异值降序排列) } \lambda_1 = 9 \text{ 对应特征向量: } v_1 = (0, 1)^T \\ \lambda_2 = 4 \text{ 对应特征向量: } v_2 = (1, 0)^T \quad V = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

Step 4: 求 U $u_1 = \frac{1}{\sigma_1}Av_1 = \frac{1}{3} \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix} \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \frac{1}{3} \begin{pmatrix} 0 \\ 3 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$

$$u_2 = \frac{1}{\sigma_2}Av_2 = \frac{1}{2} \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \frac{1}{2} \begin{pmatrix} 2 \\ 0 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

$$U = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

Step 5: 验证 $A = U\Sigma V^T$

$$\begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 3 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}^T = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 3 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} 0 & 2 \\ 3 & 0 \end{pmatrix} \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix} = A$$

因此:

$$U = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} 3 & 0 \\ 0 & 2 \end{pmatrix}, \quad V = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

第 13 章 模拟试题

一、选择题

1. 机器学习中，以下哪个不属于基本术语？
A. 样本 B. 特征 C. 算法复杂度 D. 训练集
2. 关于 NFL 定理，下列说法正确的是：
A. 所有算法在所有问题上性能相同 B. 在具体问题中算法可能有优劣 C. 算法选择不重要
D. NFL 定理否定归纳偏好
3. 10 折交叉验证中，每次用于训练的样本比例约为：
A. 90% B. 80% C. 70% D. 100%
4. 以下哪个不是防止过拟合的方法？
A. 正则化 B. 早停 C. 增加训练轮数 D. 数据增强
5. 线性回归中，最小二乘法的闭式解为：
A. $\hat{\mathbf{w}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$ B. $\hat{\mathbf{w}} = \mathbf{X}^T (\mathbf{X} \mathbf{X}^T)^{-1} \mathbf{y}$ C. $\hat{\mathbf{w}} = \mathbf{X}^{-1} \mathbf{y}$ D. $\hat{\mathbf{w}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{y}$
6. ID3 算法使用的划分选择准则是：
A. 增益率 B. 基尼指数 C. 信息增益 D. 均方误差
7. 感知机无法解决以下哪个问题？
A. 与运算 B. 或运算 C. 非运算 D. 异或运算
8. SVM 中，核函数的作用是：
A. 减少训练时间 B. 避免过拟合 C. 隐式计算高维内积 D. 增加特征维度
9. 朴素贝叶斯分类器基于的假设是：
A. 属性完全相关 B. 属性条件独立 C. 属性服从正态分布 D. 属性线性可分
10. AdaBoost 中，被错误分类的样本权重会：
A. 增大 B. 减小 C. 不变 D. 重置为零

11. K-Means 算法的优化目标是:

- A. 最大化类间距离 B. 最小化簇内平方误差 C. 最大化似然函数 D. 最小化熵

12. PCA 的优化目标等价于:

- A. 最大化投影方差 B. 最小化样本距离 C. 最大化类间散度 D. 最小化类内散度

参考答案与解析

答案: 1. C 2. B 3. A 4. C 5. A 6. C 7. D 8. C 9. B 10. A 11. B

12. A 解析:

1. 算法复杂度不属于机器学习基本术语。
2. NFL 定理指出所有算法的期望性能相同,但在具体问题中算法有优劣。
3. 10 折交叉验证每次用 9 折训练,即 90%。
4. 增加训练轮数可能加剧过拟合。
5. 最小二乘法闭式解: $\hat{\mathbf{w}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$ 。
6. ID3 使用信息增益准则。
7. 异或问题是线性不可分的,感知机无法解决。
8. 核函数隐式计算高维内积,避免维数灾难。
9. 朴素贝叶斯基于属性条件独立性假设。
10. AdaBoost 中错误样本权重增大。
11. K-Means 最小化簇内平方误差和。
12. PCA 等价于最大化投影方差。

二、填空题

1. 机器学习利用_____来改善系统自身的性能。
2. 信息熵越_____,数据集纯度越高。
3. SVM 中起到决定作用的少数训练样本称为_____。
4. 拉普拉斯修正的目的是避免概率估计值出现_____的情况。
5. Boosting 主要关注降低_____, Bagging 主要关注降低_____。

6. DBSCAN 算法需要用户指定的两个参数是_____和_____。
7. PCA 在进行特征值分解前，通常先对样本进行_____。
8. LASSO 回归通过_____范数正则化实现自动特征选择。

参考答案与解析

答案：1. 经验（数据） 2. 小（低） 3. 支持向量 4. 0 5. 偏差；方差 6. ϵ （邻域半径）；MinPts（密度阈值） 7. 中心化 8. L_1 （L1）解析：

1. 机器学习通过经验（数据）改善系统性能。
2. 信息熵越小，数据集纯度越高。
3. 支持向量是距离超平面最近的训练样本。
4. 拉普拉斯修正防止零概率导致“一票否决”。
5. Boosting 侧重降低偏差，Bagging 侧重降低方差。
6. DBSCAN 需要邻域半径 ϵ 和密度阈值 MinPts。
7. PCA 需先中心化使样本均值为 0。
8. LASSO 使用 L_1 范数正则化，产生稀疏解。

三、简答题

1. 简述过拟合的定义及三种防止过拟合的方法。
2. 简述偏差-方差分解的含义。
3. 简述 SVM 中引入核函数的动机。
4. 简述 Bagging 与 Boosting 的主要区别。

参考答案与解析

1. **过拟合**指学习器把训练样本学得“好”，将训练样本自身特点当作所有潜在样本的一般性质，导致泛化性能下降。三种防止过拟合方法：**(1) 正则化**：在损失函数中加模型复杂度惩罚项；**(2) 早停**：用验证集监控，误差不再下降时终止；**(3) Dropout**：随机丢弃部分神经元。（答出正则化、早停、数据增强、Dropout 中任意三种即可）
2. **偏差-方差分解**将泛化误差分解为偏差、方差和噪声三部分。偏差度量期望预测与真实值的偏离程度（欠拟合），方差度量预测的波动程度（过拟合）。模型复杂度增加时，偏差降低、方差升高，存在权衡（trade-off）。
3. 当样本在原始空间中线性不可分时，通过核函数 $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$ 将样本隐式映射到高维特征空间，使其线性可分。核函数避免直接计算高维映射，从而避免了维数灾难。
4. **Bagging**: 基于自助采样并行生成基学习器, 投票/平均结合, 主要降低方差。**Boosting**: 串行生成基学习器, 调整样本权重使后续学习器关注错误样本, 加权结合, 主要降低偏差。

四、综合应用题

1. 给定混淆矩阵:

	预测正例	预测反例
真实正例	90	10
真实反例	30	70

计算: (1) Accuracy (2) Precision (3) Recall (4) F_1 值。

2. 给定 6 个二维点: $A(0, 2), B(0, 0), C(1, 0), D(5, 0), E(5, 2), F(4, 3)$, 用 K-Means 聚类 ($k = 2$), 初始中心 $m_1 = (0, 0), m_2 = (5, 2)$, 求一次迭代后的簇分配和新中心。

参考答案与解析

1. 由混淆矩阵: TP=90, FN=10, FP=30, TN=70, N=200

$$(1) \text{ Accuracy} = \frac{90 + 70}{200} = 0.8$$

$$(2) \text{ Precision} = \frac{90}{90 + 30} = 0.75$$

$$(3) \text{ Recall} = \frac{90}{90 + 10} = 0.9$$

$$(4) F_1 = \frac{2 \times 0.75 \times 0.9}{0.75 + 0.9} = \frac{1.35}{1.65} \approx 0.818$$

2. 各点到 $m_1(0, 0)$ 距离: $A : 2, B : 0, C : 1, D : 5, E : \sqrt{29} \approx 5.385, F : 5$

各点到 $m_2(5, 2)$ 距离: $A : 5, B : \sqrt{29} \approx 5.385, C : \sqrt{20} \approx 4.472, D : 2, E : 0, F : \sqrt{2} \approx 1.414$

簇 1: $\{A, B, C\}$, 新中心 $m'_1 = (\frac{1}{3}, \frac{2}{3}) \approx (0.333, 0.667)$

簇 2: $\{D, E, F\}$, 新中心 $m'_2 = (\frac{14}{3}, \frac{5}{3}) \approx (4.667, 1.667)$

第 14 章 考前速记手册

速记卡 1：第 1 章绪论

机器学习基本概念

- [必记]机器学习：利用经验（数据）改善系统性能。
- [必记]版本空间：与训练集一致的假设构成的集合。
- [必记]NFL 定理：不存在普遍最优的算法，算法优劣取决于问题。
- [必记]奥卡姆剃刀：选择最简单的假设。
- [公式]关键术语：样本、特征、特征空间、标签、训练集、测试集。

[易错]NFL 定理并不否定具体问题中精心选择算法的重要性。

速记卡 2：第 2 章模型评估与选择

评估方法与性能度量

- [必记]过拟合：将训练样本自身特点当作一般性质，泛化下降。
- [必记]评估方法：留出法、交叉验证法 ($k = 10$)、留一法、自助法。
- [公式]混淆矩阵指标：

$$P = \frac{TP}{TP + FP}, \quad R = \frac{TP}{TP + FN}, \quad F_1 = \frac{2PR}{P + R}$$

- [公式]偏差-方差分解：泛化误差 = 偏差² + 方差 + 噪声。
- [必记]正则化、早停、Dropout、数据增强 → 防止过拟合。

速记卡 3：第 3 章线性模型

线性回归 & 逻辑回归

- [公式] 线性模型: $f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$ 。
- [公式] 最小二乘法闭式解: $\hat{\mathbf{w}}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$ 。
- [必记] 逻辑回归使用 Sigmoid 函数: $y = \frac{1}{1 + e^{-z}}$, 用于分类。
- [必记] LDA: 最大化 $\frac{\mathbf{w}^T \mathbf{S}_b \mathbf{w}}{\mathbf{w}^T \mathbf{S}_w \mathbf{w}}$ (广义瑞利商)。
- [必记] 类别不平衡处理: 欠采样、过采样 (SMOTE)、阈值移动。

[易错] 当 $\mathbf{X}^T \mathbf{X}$ 不可逆时, 最小二乘法闭式解不可计算。

速记卡 4：第 4 章决策树 & 第 5 章神经网络

决策树 & 神经网络

- [公式] 信息熵: $\text{Ent}(D) = -\sum p_k \log_2 p_k$ 。
- [必记] ID3: 信息增益; C4.5: 增益率; CART: 基尼指数。
- [必记] 剪枝: 预剪枝 (效率高, 可能欠拟合), 后剪枝 (效果好, 效率低)。
- [必记] 感知机只能处理线性可分问题, 多层网络可处理非线性。
- [必记] BP 算法: 前向传播 $\rightarrow$ 计算误差 $\rightarrow$ 反向传播更新权重。
- [公式] Sigmoid: $\sigma(x) = \frac{1}{1+e^{-x}}$, ReLU: $\max(0, x)$ 。

[易错] ReLU 可缓解梯度消失问题, Sigmoid/tanh 在深层网络中易梯度消失。

速记卡 5：第 6 章支持向量机

SVM 核心要点

- [必记] 最大化间隔： $\min \frac{1}{2} \|\mathbf{w}\|^2$ ，约束 $y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$ 。
- [必记] 支持向量：使约束等号成立的样本，决定最终模型（稀疏性）。
- [必记] 对偶问题：用拉格朗日乘子法，SMO 算法求解。
- [必记] 核函数：隐式映射到高维空间，常用高斯核 (RBF)。
- [必记] 软间隔：引入松弛变量 ξ_i 和惩罚参数 C 。
- [公式] 高斯核： $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma^2}\right)$ 。

[易错] 核函数必须满足 Mercer 条件（半正定性）。

速记卡 6：第 7 章贝叶斯分类器 & 第 8 章集成学习

贝叶斯 & 集成学习

- [必记] 朴素贝叶斯： $P(c|\mathbf{x}) \propto P(c) \prod P(x_i|c)$ （属性条件独立）。
- [必记] 拉普拉斯修正：分子加 1，分母加类别数，防止零概率。
- [必记] 集成学习：个体学习器好“而不同”。
- [必记] AdaBoost：串行，调整样本权重， $\alpha_t = \frac{1}{2} \ln \frac{1-\epsilon_t}{\epsilon_t}$ 。
- [必记] Bagging/随机森林：并行，自助采样，主要降低方差。
- [必记] 随机森林 = Bagging + 随机属性选择（ $k = \log_2 d$ ）。

[易错] Boosting 主要降低偏差，Bagging 主要降低方差。

速记卡 7: 第 9 章聚类 & 第 10 章降维与度量学习

聚类 & 降维

- [必记]K-Means: 最小化平方误差 $\sum \|x - \mu_i\|_2^2$ 。
- [必记]DBSCAN: 密度聚类, 参数 ϵ 和 MinPts, 可发现任意形状簇。
- [必记]AGNES: 自底向上凝聚层次聚类, 树状图展示。
- [必记]PCA: 最大化投影方差, 对协方差矩阵做特征值分解。
- [必记]流形学习: Isomap (测地距离 + MDS), LLE (局部线性嵌入)。
- [公式]闵可夫斯基距离: $(\sum |x_{iu} - x_{ju}|^p)^{1/p}$, $p = 2$ 为欧氏距离。

[易错]DBI 指数越小越好, DI 指数越大越好。

速记卡 8: 第 11 章特征选择与稀疏学习

特征选择 & 稀疏学习

- [必记]三种特征选择: 过滤式 (Relief)、包裹式 (LVW)、嵌入式 (LASSO)。
- [必记]LASSO (L_1 正则化): 产生稀疏解, 自动特征选择。
- [公式]LASSO: $\min \frac{1}{2} \|Xw - y\|_2^2 + \lambda \|w\|_1$ 。
- [必记]岭回归 (L_2 正则化): $\min \frac{1}{2} \|Xw - y\|_2^2 + \lambda \|w\|_2^2$ 。
- [必记]稀疏表示: 将样本表示为稀疏线性组合, 大部分系数为 0。
- [必记]字典学习: 交替优化——稀疏编码和字典更新。
- [必记]压缩感知: 从少量采样恢复原始信号, 利用信号稀疏性。

[易错] L_1 范数诱导稀疏, L_2 范数使权重均衡。