

数据分析与数据挖掘 完整复习资料（含 模拟试题与速记手册）

子冉一人 整理

2026 年 7 月 12 日

目录

第一章 引言	5
1.1 从数据到知识——为什么需要数据挖掘	5
1.2 数据挖掘可以挖掘什么类型的模式?	5
1.3 模式有趣吗? ——兴趣度度量	6
1.3.1 知识扩展——数据挖掘核心概念	6
第二章 数据仓库和数据挖掘的 OLAP 技术	8
2.1 数据仓库基础	8
2.1.1 什么是数据仓库?	8
2.1.2 操作数据库系统 vs 数据仓库	8
2.2 多维数据模型	8
2.2.1 数据立方体	8
2.2.2 星形模式 vs 雪花模式	9
2.3 概念分层	10
2.4 OLAP 操作	10
2.4.1 OLAP 服务器类型	10
2.4.2 OLTP vs OLAP vs OLAM	10
2.4.3 知识扩展——数据仓库相关概念	11
第三章 数据预处理	12
3.1 数据清理	12
3.1.1 缺失值处理	12
3.1.2 噪声数据处理	12
3.2 数据集成	12
3.3 数据变换与数据归约	13
3.3.1 规范化方法	13
3.3.2 数据归约策略	13
3.3.3 维归约——属性子集选择	13

3.3.4 知识扩展——预处理相关概念	14
第四章 数据挖掘原语、语言和系统结构	15
4.1 五大数据挖掘原语	15
4.2 DMQL——数据挖掘查询语言	15
4.2.1 知识扩展——原语相关概念	15
第五章 概念描述：特征与比较	17
5.1 什么是概念描述？	17
5.2 面向属性归纳（AOI）	17
5.2.1 工作原理	17
5.2.2 泛化控制参数	17
5.2.3 知识扩展——概念描述相关概念	18
第六章 挖掘大型数据库中的关联规则	19
6.1 基本概念	19
6.1.1 核心度量	19
6.2 Apriori 算法	19
6.2.1 算法流程	20
6.2.2 改进方法	20
6.3 FP-growth 算法	20
6.4 强关联规则不一定有趣	21
6.4.1 知识扩展——关联规则相关概念	22
第七章 分类和预测	23
7.1 分类的基本概念	23
7.2 决策树分类	23
7.2.1 属性选择度量	23
7.2.2 剪枝——防止过拟合	24
7.3 贝叶斯分类	24
7.4 遗传算法	24
7.5 分类器评估指标	25
7.6 集成方法	25

7.6.1	Bagging (装袋)	25
7.6.2	Boosting (提升)	26
7.6.3	知识扩展——分类相关概念	26
第八章	聚类分析 (第 1 节 ~ 第 4 节)	28
8.1	聚类分析概述	28
8.2	相异度与距离度量	28
8.2.1	闵可夫斯基距离	28
8.2.2	不同类型变量的相异度	28
8.3	划分方法	29
8.3.1	k -means 算法	29
8.3.2	k -means 的优缺点	29
8.3.3	k -medoids 算法	30
8.4	其他聚类方法概述	30
8.4.1	层次方法	30
8.4.2	基于密度的方法	31
8.4.3	基于网格的方法	31
8.4.4	知识扩展——聚类相关概念	31
第九章	模拟试题	33
第十章	考前速记手册	38
第十一章	附录：历年真题与参考答案	41
11.1	22 级期末考试真题	41
11.2	22 级参考答案	41
11.3	2026 期中考试真题	42

第1章 引言

从数据到知识——为什么需要数据挖掘

我们生活在数据爆炸的时代。商业销售、科学研究、医疗记录、社交媒体……每天都在产生海量数据。然而，数据丰富，但信息贫乏——没有有效的工具，这些数据只能躺在数据库里变成“数据坟墓”。

数据挖掘正是为了解决这一问题而生：从大量数据中挖掘出隐含的、先前未知的、对决策有潜在价值的知识和模式。




图 1.1: KDD（数据库中的知识发现）完整流程

KDD 与数据挖掘的关系：数据挖掘只是 KDD 流程中的一个核心步骤。KDD 还包括数据预处理、模式评估等环节，是一个迭代的过程。

数据挖掘可以挖掘什么类型的模式？

1. **概念/类描述**——对数据做汇总描述，如“某产品的典型客户画像”
2. **关联分析**——发现项集之间有趣的关联关系，如“尿布 $\Rightarrow$ 啤酒”（购物篮分析）
3. **分类和预测**——构造模型预测类别或连续值
4. **聚类分析**——无监督地将对象分组，使组内相似、组间相异
5. **离群点分析**——检测异常数据（欺诈检测、故障诊断）
6. **演变分析**——发现数据随时间变化的规律

购物篮分析经典案例

沃尔玛的数据挖掘工程师发现：美国超市里，**尿布和啤酒**的销售存在强关联。进一步调查发现，年轻父亲在周五下班后买尿布时会顺手买啤酒犒劳自己。于是沃尔玛将尿布和啤酒摆在一起，销量大增。

模式有趣吗？——兴趣度度量

并非所有挖掘出的模式都有价值。一个模式是否有意义，取决于：

- **易于理解**：模式应能被用户理解
- **有效性**：对新数据也有一定的可信度
- **潜在有用性**：能指导行动或决策
- **新颖性**：模式是先前未知的

补充：数据挖掘是多学科交叉领域，涉及统计学、机器学习、数据库技术、信息检索等。

知识扩展——数据挖掘核心概念

数据挖掘（Data Mining）

数据挖掘是指从大量数据中挖掘出隐含的、先前未知的、对决策有潜在价值的知识和模式的过程。它是 KDD 的核心步骤。

KDD（Knowledge Discovery in Database，数据库中的知识发现）

KDD 是从数据集中识别出有效的、新颖的、潜在有用的、最终可理解的模式的完整过程。数据挖掘只是 KDD 中的一个基本步骤。完整流程：数据清理 → 数据集成 → 数据选择 → 数据变换 → 数据挖掘 → 模式评估 → 知识表示。

概念/类描述（Concept/Class Description）

概念描述是一种描述性数据挖掘方法，对给定的数据集进行简洁、汇总性的描述。可分为特征化（Characterization）和比较/区分（Discrimination）。

关联分析（Association Analysis）

用于发现数据项之间潜在的关联关系，典型应用是购物篮分析。输出形式为关联规则 $A \Rightarrow B$ 。

分类（Classification）

分类是一种有监督学习，通过分析已知类别的训练数据集构造分类模型（分类器），然后对未知类别的数据进行类别预测。

聚类分析 (Cluster Analysis)

聚类是一种无监督学习，将数据集中的对象划分成若干个簇 (Cluster)，使得同一簇内的对象相似度高，不同簇间的对象相似度低。

离群点分析 (Outlier Analysis)

检测数据集中与一般行为或模型不一致的异常数据对象，也称为异常检测。

第2章 数据仓库和数据挖掘的 OLAP 技术

数据仓库基础

什么是数据仓库？

数据仓库（Data Warehouse）是一个面向主题的、集成的、随时间变化的、非易失的数据集合，用于支持管理决策过程。




图 2.1: 数据仓库的四大特征

操作数据库系统 vs 数据仓库

对比维度	OLTP（操作数据库）	数据仓库
用途	日常事务处理	分析决策支持
用户	事务处理人员	决策分析人员
数据内容	当前、细节	历史、汇总
访问模式	频繁读写	以读为主
响应时间	毫秒级	秒级可接受

表 2.1: OLTP 与数据仓库对比

多维数据模型

数据立方体

数据立方体（Data Cube）是多维数据模型的核心，允许从多个维度观察数据。

理解数据立方体

想象一个销售数据立方体，三个维度是：**时间**（1 月、2 月、3 月等）、**产品**（电脑、手机、平板等）、**地区**（北京、上海、广州等）。每个交叉点的**度量值**是销售额。这样你就可以回答“2026 年 1 月北京地区电脑卖了多少钱？”这样的问题。

知识点扩展：

- 方体格（Lattice of Cuboids）：不同汇总程度的数据立方体集合。
- 基本方体（Base Cuboid）和顶点方体（Apex Cuboid）。
- 物化策略：完全物化、部分物化（冰山立方体）、不物化。

星形模式 vs 雪花模式




图 2.2: 星形模式与雪花模式对比（以销售为例）

对比：

- **星形模式：**一个事实表 + 多个维表，查询效率高
- **雪花模式：**维表进一步规范化，存储省但查询复杂

概念分层

概念分层（**Concept Hierarchy**）定义从低层概念到高层概念的映射，是 OLAP 操作和多层挖掘的基础。




图 2.3: 地点维度的概念分层示例

OLAP 操作

操作	含义	示例
上卷（ Roll-up ）	沿概念分层向上汇总	从”城市”上卷到”省份”
钻取（ Drill-down ）	沿概念分层向下细化	从”季度”下钻到”月份”
切片（ Slice ）	选定某维的某个值	只看”北京”的数据
切块（ Dice ）	选定多维的子区间	北京地区 2026 年 Q1
旋转（ Pivot ）	改变维度排列视角	行列互换重新观察

表 2.2: OLAP 五种基本操作

OLAP 服务器类型

- **ROLAP**（关系 OLAP）：在关系数据库上扩展实现，用 SQL 操作
- **MOLAP**（多维 OLAP）：直接使用多维数组存储，速度快
- **HOLAP**（混合 OLAP）：结合二者优点，热点数据用 MOLAP，历史用 ROLAP

OLTP vs OLAP vs OLAM

OLAM（联机分析挖掘）将 OLAP 和数据挖掘集成，用户可在多维空间中交互挖掘。



图 2.4: OLTP → OLAP → OLAM 的演进关系

知识扩展——数据仓库相关概念

数据集市 (Data Mart)

数据集市是数据仓库的一个子集，面向特定的部门或功能需求，通常规模较小、聚焦于某个主题领域。

元数据 (Metadata)

元数据是关于数据的数据，用于描述数据仓库中数据的结构、来源、转换规则、使用方式等信息。

上卷 (Roll-up) 与钻取 (Drill-down)

上卷是通过沿概念分层向上移动或通过维归约，在更粗的粒度上对数据进行汇总。钻取是上卷的逆操作，从粗粒度向细粒度下钻，获取更详细的数据。

OLAP (联机分析处理)

OLAP 是一种对多维数据进行分析的技术，支持汇总、合并、聚集以及从不同角度观察信息的能力。

OLTP (联机事务处理)

OLTP 是操作型数据库的主要处理模式，侧重于日常事务的增删改查，强调并发性、原子性和快速响应。

OLAM (联机分析挖掘)

OLAM 将 OLAP 与数据挖掘功能集成，允许用户在多维空间中以交互方式进行数据挖掘。

第3章 数据预处理

为什么需要数据预处理？现实世界的的数据通常是：不完整的（缺值）、有噪声的（错误值）、不一致的（格式冲突）。不经过处理的数据直接挖掘，结果不可靠——”垃圾进，垃圾出”（Garbage In, Garbage Out）。

数据清理

缺失值处理

- 忽略元组：直接删除含缺失值的记录（简单但浪费数据）
- 人工填写：耗时，不适用于大数据
- 全局常量：用一个常量填充（如”unknown”）——可能误导挖掘
- 属性均值/中位数：用该属性的均值/中位数填充
- 最可能值：用回归、贝叶斯推断等方法预测最可能的值（精度最高）

噪声数据处理

噪声是变量的随机误差或方差。处理噪声的常用方法：

分箱（Binning）：将排序后的数据分配到”箱子”中，用箱均值/中位数/边界平滑。

分箱示例

原始价格数据（排序后）：4, 8, 15, 21, 21, 24, 25, 28, 34

等深分箱（每个箱 3 个值）：

- 箱 1：4, 8, 15 → 箱均值平滑：9, 9, 9
- 箱 2：21, 21, 24 → 箱均值平滑：22, 22, 22
- 箱 3：25, 28, 34 → 箱均值平滑：29, 29, 29

其他方法还有：**聚类**（离群点自动被排除）、**回归**（拟合平滑曲线）。

数据集成

将多个数据源合并到一个一致的数据存储中。主要挑战：

- 实体识别：不同源的同一实体如何匹配？
- 冗余检测：通过相关性分析发现重复或冗余属性
- 冲突处理：不同源对同一数据的不同表示如何统一？

数据变换与数据归约

规范化方法

方法	公式	特点
最小 - 最大规范化	$v' = \frac{v - \min}{\max - \min} \cdot (\text{new_max} - \text{new_min}) + \text{new_min}$	保留原始数据关系
z-score 规范化	$v' = \frac{v - \bar{x}}{\sigma}$	适合有离群点的数据
小数定标规范化	$v' = \frac{v}{10^j}$	通过移动小数点

表 3.1: 三种规范化方法对比

数据归约策略




图 3.1: 数据归约的主要策略

维归约——属性子集选择

常用方法：

- 逐步向前选择：从空集开始，每次加入最优属性
- 逐步向后删除：从全集中每次删除最差属性
- 决策树归纳：用决策树自动选择重要属性
- PCA：主成分分析，将高维数据映射到低维

知识扩展——预处理相关概念

数据清理 (Data Cleaning)

数据清理是指对数据中的缺失值、噪声数据和异常值进行处理的过程。

数据变换 (Data Transformation)

数据变换是将数据转换成适合挖掘的形式过程。常见策略：平滑 (Smoothing)、聚集 (Aggregation)、泛化 (Generalization)、规范化 (Normalization)、属性构造 (Attribute Construction)。

数据归约 (Data Reduction)

数据归约是在保持原有数据特征的前提下，获得数据集的简化表示，以减少数据量但产生相同或相近的分析结果。

离散化 (Discretization)

离散化是将连续属性的值域划分为若干区间，用区间标签代替具体数值的过程。方法：分箱（等宽/等深）、直方图分析、聚类分析、决策树分析。

规范化 (Normalization)

规范化是将属性数据按比例缩放，使之落入一个特定的区间（如 $[0, 1]$ 或 $[-1, 1]$ ）。

第4章 数据挖掘原语、语言和系统结构

五大数据挖掘原语

数据挖掘原语用于规范地定义挖掘任务。一个完整的挖掘任务需要指定以下五大要素：

1. 任务相关数据：从哪些数据库、哪些表、哪些属性中挖掘？
2. 要挖掘的知识类型：关联规则？分类模型？聚类？……
3. 背景知识：如概念分层，用于在不同粒度上挖掘
4. 兴趣度度量：支持度、置信度等阈值，用于过滤无趣模式
5. 模式呈现方式：规则表、决策树、交叉表、可视化图表……

DMQL——数据挖掘查询语言

DMQL 是类 SQL 的挖掘查询语言，示例：

```
use database AllElectronics
from relation customer
in relevance to age, income, credit_rating
mine classification (class = buys_computer)
display as decision tree
```

图 4.1: DMQL 示例：定义分类任务

知识扩展——原语相关概念

数据挖掘原语 (Data Mining Primitives)

数据挖掘原语是定义数据挖掘任务的基本要素集合，用于规范地描述挖掘目标和约束条件。
五大原语：任务相关数据、要挖掘的知识类型、背景知识、兴趣度度量、模式呈现方式。

任务相关数据 (Task-Relevant Data)

任务相关数据是指与当前挖掘任务相关的数据库属性集合。指定任务相关数据可以减少挖掘范围，提高效率。

兴趣度度量 (Interestingness Measure)

兴趣度度量用于评估挖掘出的模式是否有价值，帮助过滤无趣模式。常用度量：支持度、置信度、提升度 (Lift)、 χ^2 、Kulczynski 度量。

DMQL (数据挖掘查询语言)

DMQL 是一种专门用于数据挖掘的类 SQL 查询语言，支持用规范语法定义数据挖掘任务。

第5章 概念描述：特征与比较

什么是概念描述？

概念描述是最基本的描述性数据挖掘，对任务相关数据给出简洁、汇总的描述。包括两种：

- 特征化 (Characterization)：汇总描述目标类数据的一般特征
- 比较/区分 (Discrimination)：对比目标类与对比类的差异

面向属性归纳 (AOI)

面向属性归纳 (Attribute-Oriented Induction, AOI) 是概念特征化的核心方法。

工作原理

基本思想：通过在概念分层上沿属性向上攀升，将低层数据泛化到高层概念。




图 5.1: 面向属性归纳的基本步骤

泛化控制参数

- 属性泛化阈值：一个属性最多保留多少个不同值？超过则上泛或删除
- 广义关系阈值：最终结果表最多保留多少条元组？

AOI 举例

对所有 Electronics 的客户数据进行特征化：

- 姓名（有太多不同值）→ 删除
- 出生日期 → 泛化为”年龄段”（青年/中年/老年）
- 居住地址 → 泛化为”省份”（北京/上海/广东……）

最终得到：”大部分高端客户来自上海和北京，年龄段在 30~45 岁之间的白领”

AOI vs 数据立方体方法：AOI 灵活、不需要预计算；数据立方体方法预计算后查询快，适合频繁分析。

知识扩展——概念描述相关概念

概念描述（Concept Description）

概念描述是最基本的描述性数据挖掘形式，对给定的任务相关数据给出简洁、汇总的描述，展示数据有趣的一般性质。包含特征化（Characterization）和比较/区分（Discrimination）两类。

特征化（Characterization）

特征化是概念描述的一种，对目标类数据进行汇总和概括，输出其一般性特征。实现方法：基于数据立方体的 OLAP 方法和面向属性的归纳方法。

比较/区分（Discrimination）

比较是将目标类与一个或多个对比类进行比较，突出目标类区别于对比类的特征。

面向属性归纳（Attribute-Oriented Induction, AOI）

面向属性归纳是一种数据泛化方法，通过在概念分层上沿属性向上攀升，将底层数据泛化到高层概念。

数据泛化（Data Generalization）

数据泛化是将数据库中的任务相关数据从较低概念层次抽象到较高层次的过程。

第6章 挖掘大型数据库中的关联规则

基本概念

关联规则形如 $X \Rightarrow Y$ ，表示 X 的出现蕴涵 Y 的出现。起源于购物篮分析。

核心度量

- **支持度 (Support)**: 规则在所有事务中出现的频率

$$\text{Support}(X \Rightarrow Y) = P(X \cup Y) = \frac{\text{同时包含 } X \text{ 和 } Y \text{ 的事务数}}{\text{总事务数}}$$

- **置信度 (Confidence)**: 在包含 X 的事务中同时包含 Y 的比例

$$\text{Confidence}(X \Rightarrow Y) = P(Y | X) = \frac{\text{support}(X \cup Y)}{\text{support}(X)}$$

强关联规则：同时满足最小支持度阈值和最小置信度阈值的规则。

关联规则计算示例

有 5 个事务：

TID	购买商品
T100	{尿布, 啤酒, 面包}
T200	{尿布, 啤酒}
T300	{啤酒, 面包, 牛奶}
T400	{尿布, 面包, 牛奶}
T500	{面包, 牛奶}

规则”尿布 $\Rightarrow$ 啤酒”：

$$\text{Support} = \frac{2}{5} = 40\%, \quad \text{Confidence} = \frac{2}{3} \approx 66.7\%$$

如果最小支持度 = 30%，最小置信度 = 60%，则此规则是强关联规则。

Apriori 算法

核心思想：利用 Apriori 性质——频繁项集的所有非空子集也一定是频繁的。

算法流程




图 6.1: Apriori 算法流程

改进方法

- 散列技术：用哈希表快速过滤候选
- 事务压缩：不含频繁项集的事务不再参与后续扫描
- 划分：将数据分为若干块，分别挖掘再合并
- 抽样：在数据子集上挖掘，牺牲少量精度换效率

FP-growth 算法

FP-growth (Frequent Pattern Growth) 是一种不产生候选的频繁模式挖掘方法。




图 6.2: FP-growth 算法流程

Apriori vs FP-growth

- **Apriori:** 产生大量候选, 需要多次扫描数据库, 适合稀疏数据集
- **FP-growth:** 无候选, 只需 2 次扫描, 用 FP-树压缩数据, 适合稠密数据集

强关联规则不一定有趣

虚假关联

在 10000 个事务中, 买咖啡的有 8000 人, 买茶的有 6000 人, 同时买咖啡和茶的有 5000 人。规则” 茶 $\Rightarrow$ 咖啡”:

$$\text{Support} = \frac{5000}{10000} = 50\%, \quad \text{Confidence} = \frac{5000}{6000} \approx 83.3\%$$

但买咖啡的比例是 80%, 即使不买茶也有 80% 的概率买咖啡。茶对咖啡的促进作用很小。

解决方案: 引入兴趣度度量, 如提升度 (Lift):

$$\text{Lift}(X \Rightarrow Y) = \frac{P(X \cup Y)}{P(X)P(Y)}$$

- Lift = 1: X 和 Y 独立
- Lift > 1: 正相关
- Lift < 1: 负相关

零不变度量推荐：Kulczynski 度量 + 不平衡比（IR）。

知识扩展——关联规则相关概念

关联规则（Association Rule）

关联规则是形如 $X \Rightarrow Y$ 的蕴涵式，表示项集 X 的出现蕴涵项集 Y 的出现，其中 X 和 Y 是不相交的项集。

频繁项集（Frequent Itemset）

频繁项集是指在数据集中出现频率不低于最小支持度阈值的项的集合。关联规则由频繁项集产生。

- 频繁 k -项集：包含 k 个项的频繁项集。
- 闭频繁项集：没有超集具有相同支持度的频繁项集。
- 极大频繁项集：没有频繁超集的频繁项集。

支持度（Support）

关联规则 $X \Rightarrow Y$ 的支持度是同时包含 X 和 Y 的事务占总事务的比例： $\text{Support}(X \Rightarrow Y) = P(X \cup Y)$ 。

置信度（Confidence）

关联规则 $X \Rightarrow Y$ 的置信度是包含 X 的事务中同时包含 Y 的比例： $\text{Confidence}(X \Rightarrow Y) = P(Y | X) = \frac{P(X \cup Y)}{P(X)}$ 。

Apriori 算法

Apriori 是关联规则挖掘的经典算法。它利用 Apriori 性质进行逐层搜索：先找频繁 1-项集，再生成频繁 k -项集候选，扫描数据库验证。核心步骤：连接步（自连接产生候选）+ 剪枝步（利用 Apriori 性质剪枝）。

FP-growth 算法

FP-growth 是一种不产生候选的频繁模式挖掘算法，通过构造 FP-树（频繁模式树）压缩数据库，再递归挖掘条件模式基。

强关联规则（Strong Association Rule）

满足最小支持度阈值和最小置信度阈值的关联规则称为强关联规则。但强关联规则不一定有趣——可能出现虚假的关联，需引入相关分析（提升度、 χ^2 、全置信度、Kulczynski 等）进一步评估。

第7章 分类和预测

分类的基本概念

分类是一种有监督学习：用已知类别的训练数据构建分类模型，再对未知数据进行类别预测。




图 7.1: 分类的两步过程

决策树分类

决策树是树形分类模型——内部节点测试属性，分支对应测试结果，叶节点给出类别。




图 7.2: 决策树示例：预测客户是否购买电脑

属性选择度量

- 信息增益 (ID3): $Gain(A) = Info(D) - Info_A(D)$, 选择增益最大的属性
- 增益率 (C4.5): 对多值属性做惩罚修正
- Gini 指标 (CART): $Gini(D) = 1 - \sum_{i=1}^m p_i^2$, 选择 Gini 最小的属性

剪枝——防止过拟合

- 预剪枝：在树长完全之前提前停止分裂
- 后剪枝：先生成完整的树，再移除不可靠的子树

贝叶斯分类

贝叶斯定理：

$$P(H | X) = \frac{P(X | H)P(H)}{P(X)}$$

朴素贝叶斯分类：假设各属性之间条件独立，简化计算。

朴素贝叶斯示例

预测某客户是否会买电脑，已知：

- 年龄 = <30, 是否是学生 = 是, 信用等级 = 一般
- 由训练数据得： $P(\text{买} | \text{年} < 30, \text{学生}, \text{信用})$ 和 $P(\text{不买} | \dots)$
- 比较两个概率值，取大者为最终预测

遗传算法

遗传算法（Genetic Algorithm）模拟生物进化过程进行随机搜索优化。




图 7.3: 遗传算法流程

遗传算法的特点：

- 全局搜索能力强，不易陷入局部最优
- 不依赖梯度信息，适用面广
- 并行性：种群搜索
- 缺点：收敛速度可能慢，参数选择敏感

分类器评估指标

二分类混淆矩阵

实际 \ 预测	正类	负类
正类	TP （真正例）	FN （假负例）
负类	FP （假正例）	TN （真负例）

$$\text{准确率 (Accuracy)} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{精确率 (Precision)} = \frac{TP}{TP + FP}$$

$$\text{召回率/灵敏度 (Recall/Sensitivity)} = \frac{TP}{TP + FN}$$

$$\text{特异度 (Specificity)} = \frac{TN}{TN + FP}$$

$$F_1 \text{ 分数} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

评估指标的应用场景

垃圾邮件分类：更关心**精确率**——误将正常邮件判为垃圾邮件的代价很大。

疾病诊断：更关心**召回率**——漏诊比误诊更严重，尽可能找出所有患病者。

综合评价用 F_1 分数，平衡精确率和召回率。

集成方法

Bagging（装袋）

- 有放回地抽样生成 k 个训练子集
- 分别训练 k 个分类器

- **等权投票**决定最终类别
- 能降低方差，提高稳定性，不易过拟合

Boosting（提升）

- 迭代训练，每轮增加误分类样本的权重
- AdaBoost 是经典实现
- **加权投票**（准确率高的分类器权重更大）
- 可能过拟合，对噪声更敏感

Bagging vs Boosting

- Bagging **并行**训练，Boosting **串行**加权
- Bagging 等权投票，Boosting 加权投票
- Bagging 对噪声更鲁棒，Boosting 可能过拟合
- 可以类比：Bagging 像多数医生会诊，Boosting 像专家递进诊断

知识扩展——分类相关概念

分类（Classification）

分类是一种监督学习方法，通过训练集构建分类模型，将数据映射到预定义的类别标签上。
两步过程：训练（构建模型）→ 分类（预测新样本的类别标签）。

决策树（Decision Tree）

决策树是一种树形分类模型，每个内部节点表示一个属性上的测试，每个分支表示测试输出，每个叶节点表示类别。算法：Hunt 算法、ID3、C4.5、CART。

贝叶斯分类（Bayesian Classification）

贝叶斯分类是基于贝叶斯定理的概率分类方法。朴素贝叶斯假设属性之间条件独立，简化计算。

遗传算法（Genetic Algorithm）

遗传算法是一种基于自然选择和遗传机制的随机搜索优化算法，常用于优化分类规则中的参数。基本操作：选择（Selection）→ 交叉（Crossover）→ 变异（Mutation）。

准确率（Accuracy）

分类准确率是分类器正确分类的样本数占总样本数的比例：
$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN}。$$

精确率 (Precision)

精确率是预测为正类的样本中真正为正类的比例: $\text{Precision} = \frac{TP}{TP+FP}$ 。

召回率/灵敏度 (Recall/Sensitivity)

召回率 (也称灵敏度、真正例率) 是真正的正类样本中被正确预测为正类的比例: $\text{Recall} = \frac{TP}{TP+FN}$ 。

特异度 (Specificity)

特异度 (真负例率) 是真正的负类样本中被正确预测为负类的比例: $\text{Specificity} = \frac{TN}{TN+FP}$ 。

F_1 分数

F_1 分数是精确率和召回率的调和平均: $F_1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$ 。

过拟合 (Overfitting)

过拟合是指分类模型过度适合训练数据, 导致在训练集上表现很好但在测试集上表现很差的现象。原因: 模型过于复杂, 学习到了训练数据中的噪声。解决: 决策树剪枝、交叉验证、正则化、增加训练数据。

装袋 (Bagging, Bootstrap Aggregating)

装袋是一种集成学习方法, 通过对训练集有放回地抽样产生 k 个不同训练子集, 分别训练分类器后投票决定最终分类。能降低方差, 提高稳定性。

提升 (Boosting)

提升是一种迭代的集成学习方法, 每次迭代都增加对前一轮误分类样本的关注, 最终加权投票决定分类。AdaBoost 是最经典的提升算法。

第8章 聚类分析（第1节～第4节）

聚类分析概述

聚类分析是一种无监督学习——将对象划分成簇，使得簇内相似度高、簇间相似度低。




图 8.1: 聚类效果示意图

相异度与距离度量

闵可夫斯基距离

$$d(i, j) = \sqrt[q]{\sum_{f=1}^p |x_{if} - x_{jf}|^q}$$

- $q = 1$: 曼哈顿距离（街区距离）
- $q = 2$: 欧氏距离（直线距离）
- $q = \infty$: 上确界距离（切比雪夫距离）

不同类型变量的相异度

- 二元变量：对称用简单匹配系数，不对称用 Jaccard 系数
- 标称变量：简单匹配（ $d = (p - m)/p$, $m = \text{匹配数}$ ）
- 序数变量：映射到 $[0, 1]$ 后按区间标度处理
- 比例标度变量：取对数变换后再处理
- 混合类型：综合上述方法，将所有变量统一到 $[0, 1]$ 区间

划分方法

k -means 算法

k -means 是最经典的基于划分的聚类算法，以 k 为参数将 n 个对象分为 k 个簇，使簇内平方误差最小。




图 8.2: k -means 算法流程

目标函数（平方误差和）：

$$E = \sum_{i=1}^k \sum_{p \in C_i} \|p - m_i\|^2$$

其中 m_i 是簇 C_i 的质心（均值）。

k -means 的优缺点

- 优点：算法简单、时间复杂度低 $O(nkt)$
- 缺点：
 - 只能发现球状簇
 - 对初始质心敏感（不同初始值可能导致不同结果）
 - 需事先指定 k 值
 - 对噪声和离群点敏感

***k*-means 聚类示例**

有 4 个点: A(0,2), B(0,0), C(1.5,0), D(5,0)。取 $k = 2$:

1. 随机选 A(0,2) 和 D(5,0) 为初始质心
2. 计算各点到质心的距离:
 - B(0,0) 离 A 距离 2, 离 D 距离 5 $\Rightarrow$ 分配给 A 的簇
 - C(1.5,0) 离 A 距离 2.5, 离 D 距离 3.5 $\Rightarrow$ 分配给 A 的簇
3. 更新质心: 簇 1 (A,B,C) 质心 = (0.5,0.67); 簇 2(D) 质心 = (5,0)
4. 重复直到收敛……

***k*-medoids 算法**

k-medoids 用实际存在的对象（中心点）而不是平均值来表示簇中心。代表算法: **PAM**。

对比维度	<i>k</i> -means	<i>k</i> -medoids
簇中心	平均值（虚拟点）	实际数据点
对离群点	敏感	鲁棒
时间复杂度	$O(nkt)$	$O(k(n-k)^2)$
适用场景	大规模数据	小规模数据、有离群点

表 8.1: *k*-means 与 *k*-medoids 对比

其他聚类方法概述**层次方法**

- 凝聚（自底向上）: 每个对象做一个簇，逐步合并最近邻簇
- 分裂（自顶向下）: 所有对象在一个簇，逐步分裂
- 代表算法: BIRCH（CF 树）、CURE、Chameleon
- 缺陷: 合并/分裂不可撤销，错误会累积

凝聚层次聚类

有 5 个点 A~E, 最相似的一对先合并: $A \cup B \rightarrow AB$, 再合并 $AB \cup C \rightarrow ABC$, $D \cup E \rightarrow DE$, 最后 $ABC \cup DE$ 。形成树状结构（树状图）。

基于密度的方法

- 根据对象的密度（邻域内对象数）决定簇
- 能发现任意形状的簇，过滤噪声
- 代表算法：DBSCAN（基于密度连通区域）
- 对比划分方法：划分发现球状簇，密度方法发现任意形状

基于网格的方法

- 将空间量化为有限个网格单元
- 处理时间独立于数据对象数目
- 代表算法：STING（统计信息网格）

聚类方法总结

- 划分方法：球状簇，小到中规模—— k -means, k -medoids
- 层次方法：产生树状结构——BIRCH, CURE, Chameleon
- 密度方法：任意形状，过滤噪声——DBSCAN, OPTICS
- 网格方法：速度快，与数据量无关——STING, CLIQUE

知识扩展——聚类相关概念

聚类分析（Cluster Analysis）

聚类分析是将数据集中的对象划分为若干个簇的过程，使得簇内相似度高、簇间相似度低。是一种无监督学习方法。

k -means 算法

k -means 是一种基于划分的聚类算法。以 k 为参数，将 n 个对象划分到 k 个簇中，使簇内平方误差最小。算法步骤：随机选择 k 个对象作为初始簇中心 → 将每个对象分配到距离最近的簇 → 重新计算每个簇的平均值 → 重复直到簇不再变化。

k -medoids 算法

k -medoids 是一种基于划分的聚类算法，用簇中实际存在的对象（中心点）而不是平均值来表示簇中心。代表算法：PAM（Partitioning Around Medoids）。

相异度（Dissimilarity）

相异度衡量两个对象之间的差异程度，值越小越相似。常用的相异度度量包括距离函数。

闵可夫斯基距离： $d(i, j) = \sqrt[q]{\sum_{f=1}^p |x_{if} - x_{jf}|^q}$ 。

划分方法 (Partitioning Method)

划分方法是一种聚类方法，给定 n 个对象的数据集和 k 个簇的数目，构建数据的 k 个划分，每个划分代表一个簇。

层次方法 (Hierarchical Method)

层次方法通过层次分解对给定数据集进行聚类，分为凝聚（自底向上）和分裂（自顶向下）两种策略。

基于密度的方法 (Density-based Method)

基于密度的方法根据对象的密度（邻域内对象数）是否超过阈值来形成簇，能发现任意形状的簇并过滤噪声。

第9章 模拟试题

一、选择题

1. KDD 流程中，数据挖掘之前的一步是：
A. 数据清理 B. 数据变换 C. 模式评估 D. 知识表示
2. 下列哪个不是数据仓库的特征？
A. 面向主题 B. 集成的 C. 非易失的 D. 频繁更新的
3. Apriori 算法的核心思想基于：
A. 频繁项集的所有非空子集也是频繁的 B. 频繁项集的所有超集也是频繁的 C. 所有项集都是频繁的 D. 频繁项集互不相交
4. 关联规则 $X \Rightarrow Y$ 的置信度计算公式为：
A. $P(X \cup Y)$ B. $P(Y | X)$ C. $P(X | Y)$ D. $P(X)/P(Y)$
5. 下列哪个分类器假设各属性条件独立？
A. 决策树 B. 朴素贝叶斯 C. SVM D. k -NN
6. 信息增益公式 $\text{Gain}(D, a) = \text{Ent}(D) - \sum \frac{|D^v|}{|D|} \text{Ent}(D^v)$ 中， $\text{Ent}(D)$ 表示：
A. 信息熵 B. 信息增益 C. 基尼系数 D. 方差
7. 下列哪个不是数据归约的方法？
A. 维归约 B. 数据方聚集 C. 分箱 D. 数据立方体
8. 聚类分析中，DBSCAN 属于哪种方法？
A. 划分方法 B. 层次方法 C. 密度方法 D. 网格方法
9. 下列哪种集成学习方法采用等权投票？
A. Bagging B. Boosting C. AdaBoost D. GBDT
10. OLAP 操作中，从“季度”下钻到“月份”属于：
A. 上卷 B. 钻取 C. 切片 D. 旋转

11. 决策树 C4.5 算法使用什么作为属性选择度量?

- A. 信息增益 B. 增益率 C. Gini 指标 D. 卡方检验

12. k -means 算法的目标是最小化:

- A. 簇间距离 B. 平方误差和 C. 信息熵 D. 方差

参考答案与解析

答案: 1. B 2. D 3. A 4. B 5. B 6. A 7. C 8. C 9. A
10. B 11. B 12. B

解析:

1. KDD 流程: 数据清理 → 数据集成 → 数据选择 → **数据变换** → 数据挖掘 → 模式评估 → 知识表示。
2. 数据仓库的四大特征: 面向主题、集成、随时间变化、非易失。频繁更新是 OLTP 的特征。
3. Apriori 性质: 频繁项集的所有非空子集也一定是频繁的, 用于剪枝。
4. 置信度 $\text{Confidence}(X \Rightarrow Y) = P(Y|X) = \text{support}(X \cup Y) / \text{support}(X)$ 。
5. 朴素贝叶斯分类器基于属性条件独立性假设。
6. $\text{Ent}(D)$ 是信息熵, 值越小纯度越高。
7. 分箱是数据清洗(噪声处理)的方法, 不是数据归约的方法。数据归约包括: 维归约、数据方聚集、数据压缩、数值归约、离散化。
8. DBSCAN 是基于密度的方法(Density-Based Spatial Clustering of Applications with Noise)。
9. Bagging 并行训练各分类器, 等权投票决定最终类别。Boosting/AdaBoost/GBDT 均采用加权投票。
10. 钻取(Drill-down)沿概念分层向下细化数据粒度。
11. C4.5 使用增益率(Gain Ratio)克服 ID3 对多值属性的偏好。
12. k -means 最小化平方误差和 $\sum_{i=1}^k \sum_{p \in C_i} \|p - m_i\|^2$ 。

二、填空题

1. 数据仓库的四大特征为面向主题、集成、_____ 和非易失。_____

2. 决策树 C4.5 算法使用 _____ 作为属性选择度量。 _____
3. FP-growth 算法不需要 _____，只需扫描数据库 2 次。 _____
4. 混淆矩阵中， F_1 分数是 _____ 和 _____ 的调和平均。 _____
5. OLAP 操作中，从”季度”下钻到”月份”属于 _____ 操作。 _____
6. Bagging 和 Boosting 的主要区别在于 _____ 方式和 _____ 方式。 _____
7. 关联规则的提升度 $Lift = 1$ 表示 _____， $Lift > 1$ 表示 _____。 _____
8. 朴素贝叶斯分类器基于 _____ 假设。 _____

参考答案与解析

答案：1. 随时间变化 2. 增益率 3. 产生候选 4. 精确率，召回率 5. 钻取 (Drill-down) 6. 训练（并行/串行），投票 7. 独立，正相关 8. 属性条件独立

解析：

1. 数据仓库四大特征：面向主题、集成、随时间变化、非易失。
2. C4.5 使用增益率 (Gain Ratio) 克服 ID3 对多值属性的偏好。
3. FP-growth 的核心优势是不产生候选集，直接通过 FP-树挖掘。
4. $F_1 = 2 \cdot P \cdot R / (P + R)$ ， P 为精确率， R 为召回率。
5. 钻取 (Drill-down) 沿概念分层向下细化数据粒度。
6. Bagging 并行训练/等权投票；Boosting 串行加权/加权投票。
7. 提升度 $Lift = P(X \cup Y) / (P(X)P(Y))$ ， $= 1$ 独立， > 1 正相关， < 1 负相关。
8. 朴素贝叶斯核心假设：在给定类别条件下，各属性之间相互独立。

三、简答题

1. 简述 Apriori 算法中”剪枝”步骤的含义及其理论依据。
2. 比较 Bagging 和 Boosting 的异同。
3. 面对类别不平衡问题，有哪些常用处理方法？
4. 简述面向属性归纳 (AOI) 的基本思想。

5. 对比 k -means 和 k -medoids 聚类算法的优缺点。
6. 简述数据仓库的四大特征及其含义。

参考答案与解析

解析:

1. **Apriori 剪枝:** 在生成候选 k -项集 C_k 后, 利用 Apriori 性质——频繁项集的所有非空子集也一定是频繁的——移除那些包含非频繁 $(k-1)$ -子集的候选。这大幅减少了候选集大小, 提高了算法效率。
2. **Bagging vs Boosting:** 相同点是都属于集成学习方法, 通过组合多个基学习器提升性能。不同点: (1) 训练方式: Bagging 并行训练, Boosting 串行迭代; (2) 样本权重: Bagging 均匀抽样, Boosting 逐轮调整权重; (3) 投票方式: Bagging 等权投票, Boosting 加权投票; (4) 噪声容忍: Bagging 对噪声更鲁棒, Boosting 可能过拟合。
3. **类别不平衡处理:** (1) 再缩放——调整决策阈值; (2) 欠采样——减少多数类样本; (3) 过采样——增加少数类样本 (如 SMOTE); (4) 代价敏感学习——对少数类误分施以更高惩罚。
4. **AOI 基本思想:** 通过在概念分层上沿属性向上攀升, 将低层细节数据泛化到高层概念。具体步骤: 数据聚焦 $\rightarrow$ 属性删除/泛化 (设定泛化阈值) $\rightarrow$ 计数累积合并相同元组 $\rightarrow$ 得到广义关系。
5. **k -means vs k -medoids:** k -means 用平均值作为簇中心, 算法简单、时间复杂度低 $O(nkt)$, 但对离群点敏感; k -medoids 用实际数据点作为中心, 对离群点鲁棒, 但时间复杂度高 $O(k(n-k)^2)$, 不适合大数据集。
6. **数据仓库四大特征:** (1) 面向主题——按主题 (如客户、产品) 组织数据而非按应用; (2) 集成——消除源数据中的命名冲突、单位差异等不一致; (3) 随时间变化——保存 5-10 年历史数据; (4) 非易失——数据只读不修改。

四、综合应用题

1. 某超市有 5 个事务: T1{牛奶, 面包, 鸡蛋}、T2{面包, 尿布, 啤酒, 鸡蛋}、T3{牛奶, 尿布, 啤酒, 可乐}、T4{面包, 牛奶, 尿布, 啤酒}、T5{面包, 牛奶, 可乐}。设最小支持度 = 60%, 求所有频繁项集。
2. 给定混淆矩阵: TP=80, FN=20, FP=30, TN=70。计算准确率、精确率、召回率和 F_1 分数。
3. 某医院希望建立数据挖掘系统用于辅助诊疗。请设计: (1) 数据仓库的维度与度量; (2) 可能使用的数据挖掘任务和方法。

参考答案与解析

解析：

1. 频繁项集计算：

总事务数 = 5，最小支持度计数 = $5 \times 60\% = 3$ 。

1-项集：牛奶 4、面包 4、尿布 3、啤酒 3、鸡蛋 2、可乐 2。频繁 1-项集 { , , , }。

2-项集候选：{ , }3、{ , }3、{ , }2、{ , }3、{ , }2、{ , }3。频繁 2-项集 { { , }, { , }, { , }, { , } }。

3-项集候选：{ , , }3。频繁 3-项集 { { , , } }。

2. 分类器评估：

$$\text{Accuracy} = (80 + 70) / (80 + 20 + 30 + 70) = 150 / 200 = 75\%$$

$$\text{Precision} = 80 / (80 + 30) = 80 / 110 \approx 72.7\%$$

$$\text{Recall} = 80 / (80 + 20) = 80 / 100 = 80\%$$

$$F_1 = 2 \times 72.7\% \times 80\% / (72.7\% + 80\%) \approx 76.2\%$$

3. 医院数据挖掘系统设计：

(1) 数据仓库：从医院 HIS 系统抽取数据。维度：时间（年/月/日）、科室、病种、医生、患者（年龄/性别）。度量：就诊次数、费用、住院天数、药占比。

(2) 挖掘任务：分类——预测患者再入院风险（高风险提前干预）；聚类——对患者群体分群（慢病/急诊/常规），针对性管理；关联规则——挖掘药品之间的配伍关系，辅助临床决策；离群检测——识别异常诊疗费用或不合规处方。

第 10 章 考前速记手册

数据仓库与 OLAP 速记

核心概念

- [必记] 数据仓库四特征：面向主题、集成、随时间变化、非易失
- [必记] OLAP 五操作：上卷 (Roll-up)、钻取 (Drill-down)、切片 (Slice)、切块 (Dice)、旋转 (Pivot)
- [必记] 星形模式：一个事实表 + 多个维表；雪花模式：维表进一步规范化
- [公式] 概念分层：低层概念 → 高层概念（如城市 → 省份 → 国家）
- [易错] 数据仓库不是数据库！OLTP 用于事务处理，DW 用于分析决策
- [必记] 数据集市是数据仓库的子集，面向部门级应用

数据预处理速记

数据清洗与变换

- [必记] 缺失值处理 5 种方法：忽略、人工、常量、均值、最可能值（精度最高）
- [必记] 噪声处理：分箱（等深/等宽）、聚类、回归
- [公式] 最小-最大规范化： $v' = \frac{v - \min}{\max - \min}(\text{new_max} - \text{new_min}) + \text{new_min}$
- [公式] z-score： $v' = (v - \bar{x})/\sigma$
- [必记] 数据归约四策略：维归约、数据方聚集、数值归约、数据压缩
- [易错] “垃圾进，垃圾出”(GIGO)——预处理比挖掘算法更重要

关联规则速记

Apriori 与 FP-growth

- [必记] 支持度 = $P(X \cup Y)$, 置信度 = $P(Y|X)$
- [必记] Apriori 性质: 频繁项集的所有非空子集也是频繁的
- [必记] Apriori 流程: 连接 $\rightarrow$ 剪枝 $\rightarrow$ 扫描验证, 迭代产生 L_k
- [必记] FP-growth: 不产生候选, 2 次扫描, 用 FP-树压缩
- [公式] 提升度: $\text{Lift} = P(X \cup Y) / (P(X)P(Y))$, > 1 正相关
- [易错] 强关联规则不一定有趣! 需用 Lift/Kulc/IR 等兴趣度度量
- [必记] 闭频繁项集: 无同支持度超集; 极大频繁项集: 无频繁超集

分类与聚类速记

核心方法

- [必记] 决策树: ID3(信息增益)、C4.5(增益率)、CART(Gini)
- [必记] 朴素贝叶斯: 假设属性条件独立
- [公式] 贝叶斯定理: $P(H|X) = P(X|H)P(H)/P(X)$
- [公式] 混淆矩阵: $F_1 = 2PR/(P+R)$, P 精确率, R 召回率
- [必记] k -means: 最小化平方误差, 找球状簇
- [必记] Bagging(并行 + 等权) vs Boosting(串行 + 加权)
- [必记] 遗传算法三算子: 选择 (轮盘赌) $\rightarrow$ 交叉 (主搜索) $\rightarrow$ 变异 (防早熟)
- [易错] 类别不平衡时准确率有误导性——关注 F_1 分数
- [易错] k -means 对初始质心敏感, 需多次运行取最优

聚类方法速记

四大聚类方法

- [必记]划分方法: k -means(均值质心)、 k -medoids(真实点中心)——球状簇
- [必记]层次方法: AGNES(凝聚自底向上)、DIANA(分裂自顶向下)
- [必记]密度方法: DBSCAN——任意形状簇, 可识别噪声
- [必记]网格方法: STING——速度快, 与数据量无关
- [公式]闵可夫斯基距离: $d = \sqrt[q]{\sum |x_{if} - x_{jf}|^q}$
- [公式] k -means 目标函数: $E = \sum \sum \|p - m_i\|^2$

评估指标与属性类型速记

必背公式

- [公式]Accuracy = $(TP + TN) / Total$
- [公式]Precision = $TP / (TP + FP)$ ——关注误诊
- [公式]Recall/Sensitivity = $TP / (TP + FN)$ ——关注漏诊
- [公式]Specificity = $TN / (FP + TN)$
- [必记]属性四类型: 标称 (无顺序)、序数 (有顺序)、区间 (无绝对零点)、比率 (有绝对零点)
- [必记]KDD 五步: 选择 → 预处理 → 变换 → 挖掘 → 评估
- [必记]ETL: Extract(抽取)→Transform(转换)→Load(加载)
- [必记]Filter(先选再训) vs Wrapper(边搜边训) vs Embedded(选训一体)

第 11 章 附录：历年真题与参考答案

22 级期末考试真题

1. 描述常见的分类算法。
2. 解释常见的分类算法的指标的含义：准确率、精确率、特异度、灵敏度、F1 分数等。
3. 解释数据预处理中的几个过程：数据清理、数据集成、数据变换、数据归约。
4. 描述遗传算法的过程及特点。
5. 解释什么是面向属性归纳。
6. 描述常见的聚类算法。

22 级参考答案

1. 常见分类算法：
 - 决策树 (ID3/C4.5/CART)：基于信息增益/增益率/基尼指数递归划分。
 - KNN：基于 K 个最近邻居投票的惰性学习算法。
 - 朴素贝叶斯：基于贝叶斯定理和条件独立性假设。
 - SVM：寻找最大间隔超平面的二分类器。
 - 集成方法：Bagging (随机森林) 和 Boosting (AdaBoost/GBDT)。
2. 评估指标 (以二分类为例)：准确率 = $(TP + TN) / Total$ ；精确率 = $TP / (TP + FP)$ ；召回率/灵敏度 = $TP / (TP + FN)$ ；特异度 = $TN / (FP + TN)$ ；F1 分数 = $2 \times \frac{Precision \times Recall}{Precision + Recall}$ 。
3. 数据预处理四步骤：
 - 数据清理：处理缺失值 (填均值/中位数) 和平滑噪声 (分箱/聚类)。
 - 数据集成：合并多源数据，解决实体识别和冲突。
 - 数据变换：归一化/标准化/离散化/概念分层。
 - 数据归约：维归约 (PCA/特征选择)、数量归约、数据压缩、立方体聚合。
4. 遗传算法：模拟自然选择和遗传机制。步骤：初始化种群 → 适应度评估 → 选择 (轮盘赌) → 交叉 (主搜索算子) → 变异 (辅助、防早熟) → 迭代至终止。特点：全局搜索能力强，适合复杂优化问题。

5. **面向属性归纳 (AOI)**: 通过概念分层将低层数据沿属性向上概化到高层概念, 生成简洁可理解的特征描述。核心机制: 设定阈值, 属性取值过多时沿概念分层向上泛化 (属性上卷)。

6. **常见聚类算法**:

- 划分方法: K-Means (均值质心)、K-Medoids (真实点中心)。
- 层次方法: AGNES (凝聚)、DIANA (分裂)。
- 密度方法: DBSCAN (任意形状簇, 可识别噪声)。
- 网格方法: STING (速度快但精度略低)。
- 模型方法: GMM (高斯混合 + EM 算法)。

2026 期中考试真题

一、名词解释 (每题 10 分, 共 30 分)

1. 数据仓库、数据集市。
2. 元数据、元规则。
3. 初始数据关系、概念分层。

参考答案

1. **数据仓库**: 面向主题的、集成的、随时间变化的、非易失的数据集合, 用于决策支持。**数据集市**: 数据仓库的子集, 面向特定部门或应用, 范围小。
2. **元数据**: 关于数据的数据, 描述数据仓库中数据的结构、来源、定义等。**元规则**: 在数据挖掘中定义用户感兴趣模式形式的规则模板 (规则骨架/语法规则)。
3. **初始数据关系**: 未经任何泛化处理的原始关系表。**概念分层**: 定义了一组从底层具体概念到高层抽象概念的偏序映射, 用于数据泛化 (如: 城市 $\subset$ 省份 $\subset$ 国家)。

二、简答题 (每题 10 分, 共 40 分)

1. 联机事务处理 (OLTP)、联机分析处理 (OLAP) 与联机分析挖掘 (OLAM) 的区别。
2. 假定驱动的探查与发现驱动的探查的区别是什么? 如何标记例外?
3. 数据预处理主要有哪些步骤? 如何实现的?

4. 如何使用数据挖掘原语定义挖掘任务？

参考答案

1. OLTP vs OLAP vs OLAM:

- OLTP: 面向操作人员, 增删改查, 关系型数据库, 当前最新数据。
- OLAP: 面向决策者, 只读查询 (下钻/上卷/切片/旋转), 多维数据仓库, 历史聚集数据。
- OLAM: 在 OLAP 多维数据基础上自动运行挖掘算法, 实现分析与挖掘一体化。

2. 假定驱动 vs 发现驱动:

- 假定驱动 (假设验证): 用户先提出假设, 用数据验证其真伪。自上而下。
- 发现驱动 (知识发现): 系统自动在数据中寻找未知模式。自下而上。
- 标记例外: 偏离期望模式的数据点, 可用统计阈值或可视化方法识别。

3. 数据预处理步骤: 数据清理 (填缺失值/去噪声) → 数据集成 (合并多源) → 数据变换 (归一化/离散化) → 数据归约 (降维/压缩)。实现上常用工具如 Pandas 进行缺失值处理、标准化、PCA 降维等。

4. 用数据挖掘原语定义任务 (五要素): (1) 任务相关数据——指定挖掘的数据集和属性; (2) 挖掘知识类型——分类/聚类/关联等; (3) 背景知识——概念分层等; (4) 兴趣度度量——支持度/置信度阈值; (5) 模式呈现方式——表格/决策树/可视化。

三、模型建立 (30 分)

为齐鲁医院建立数据挖掘系统。包含数据仓库生成、分析处理结构和基本功能。

参考答案

- **数据仓库生成:** 从医院的 HIS 系统 (门诊/住院/检验/药品) 抽取数据, 经过 ETL 清洗转换后加载到数据仓库。维度设计: 时间 (年/月/日)、科室、病种、医生、患者 (年龄/性别/医保)。度量: 就诊次数、费用、药占比、住院天数。
- **分析处理结构:** 采用星型模式, 中央事实表 (诊疗记录) 连接多个维表。OLAP 支持: 可沿时间/科室/病种下钻上卷, 实现多维分析与报表。
- **基本功能:**
 - 分类: 预测患者再入院风险 (高风险提前干预)。

- 聚类：对患者群体分群（慢病/急诊/常规），针对性管理。
- 关联规则：挖掘药品之间的配伍关系，辅助临床决策。
- 离群检测：识别异常诊疗费用或不合规处方。